

범주형과 수치형 자료

보건빅데이터통계분석

이새봄
삼육대학교 SW융합교육원

자료란?

자료

- 삼육대학교에서 수업할 수 있는 능력을 평가하기 위한 자료?
-> 수학능력시험



자료

- 개체(Subject)
 - 관찰된 항목이나 대상, 예) 고등학교 3학년
- 요인(Factor)
 - 개체에 관한 특성 중 연구자가 관심을 갖는 특성, 예) 대학수학능력
- 변수(Variabile)
 - 요인의 특성을 수치화 하기 위해 쓰이는 속성, 예) 대학수학능력시험점수
- 척도 (Measurement)
 - 일정한 규칙을 가지고 기호 또는 숫자로 나타낸 것 , 예) 점수, cm, kg 등
- 자료(Data)
 - 관심의 대상인 사물이나 속성을 측정, 관찰, 조사한 값들의 모음, 예) 각 학생들의 개별 수능점수

자료

- 관측대상(Subject)

- 15개(1~15)

- 변수(Variable)

- 7개(성별 ~기말)

- 다변량(multivariate)자료(여러 개의 변수로 구성)

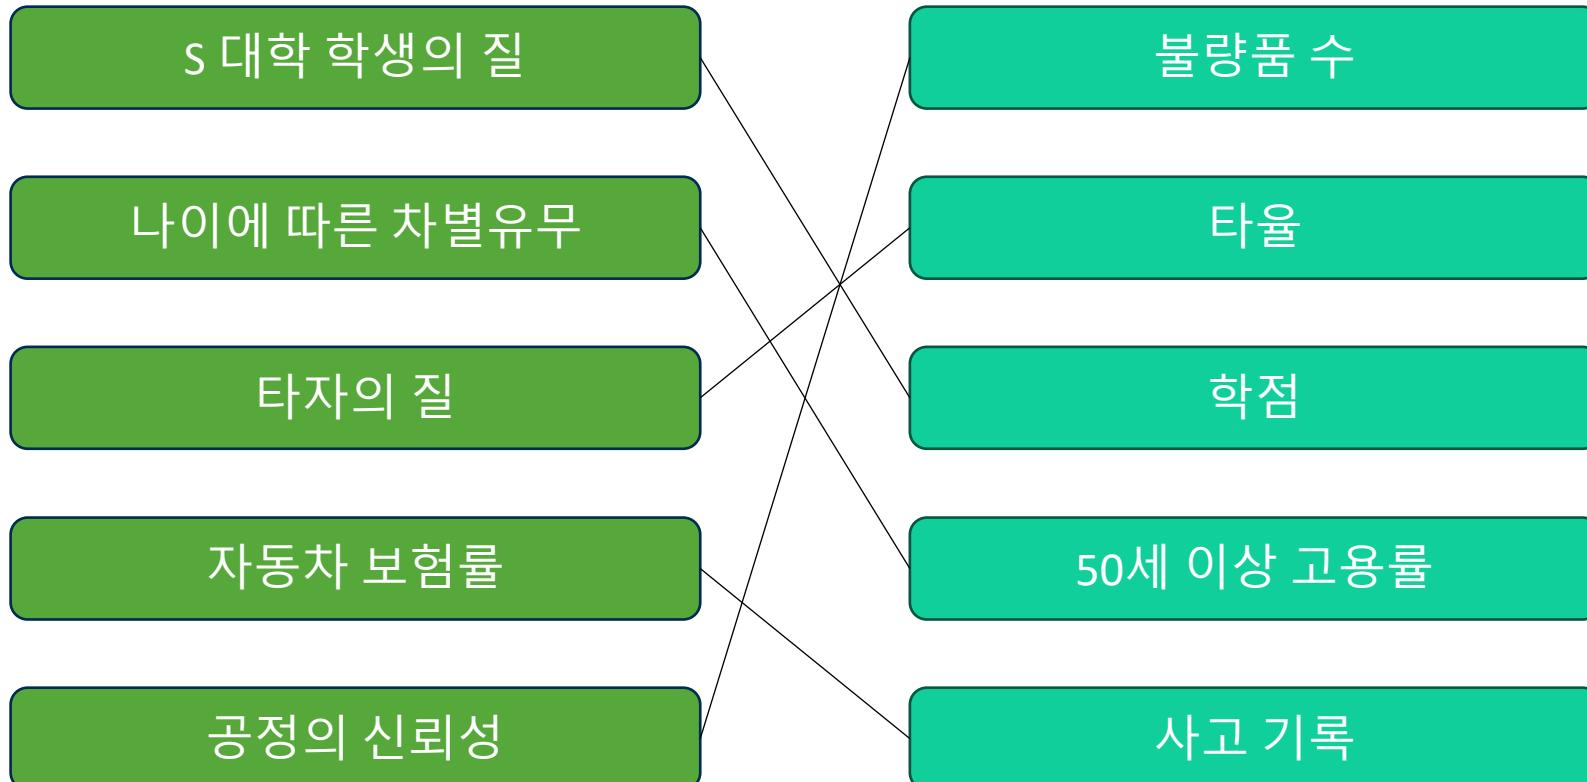
- 일변량(Univariate)자료: 하나의 변수로만 구성

- 관측치(Observations)

- $15 * 7 = 105$ 개

id	성별	분반	학년	몸무게	출석	중간	기말
1	남자	1	1	40	100	87	80
2	여자	2	2	50	100	83	60
3	남자	1	3	56	100	84	60
4	여자	2	4	51	100	73	60
5	남자	1	1	55	100	68	60
6	남자	2	2	61	100	77	50
7	여자	1	3	69	100	40	80
8	여자	2	2	44	100	73	30
9	여자	1	2	66	80	64	40
10	남자	2	2	60	100	66	40
11	여자	1	2	56	100	63	40
12	여자	2	4	72	100	76	20
13	여자	1	1	46	100	73	20
14	남자	2	2	63	100	73	20
15	남자	1	3	56	100	67	30

요인과 변수



자료가 중요한 이유

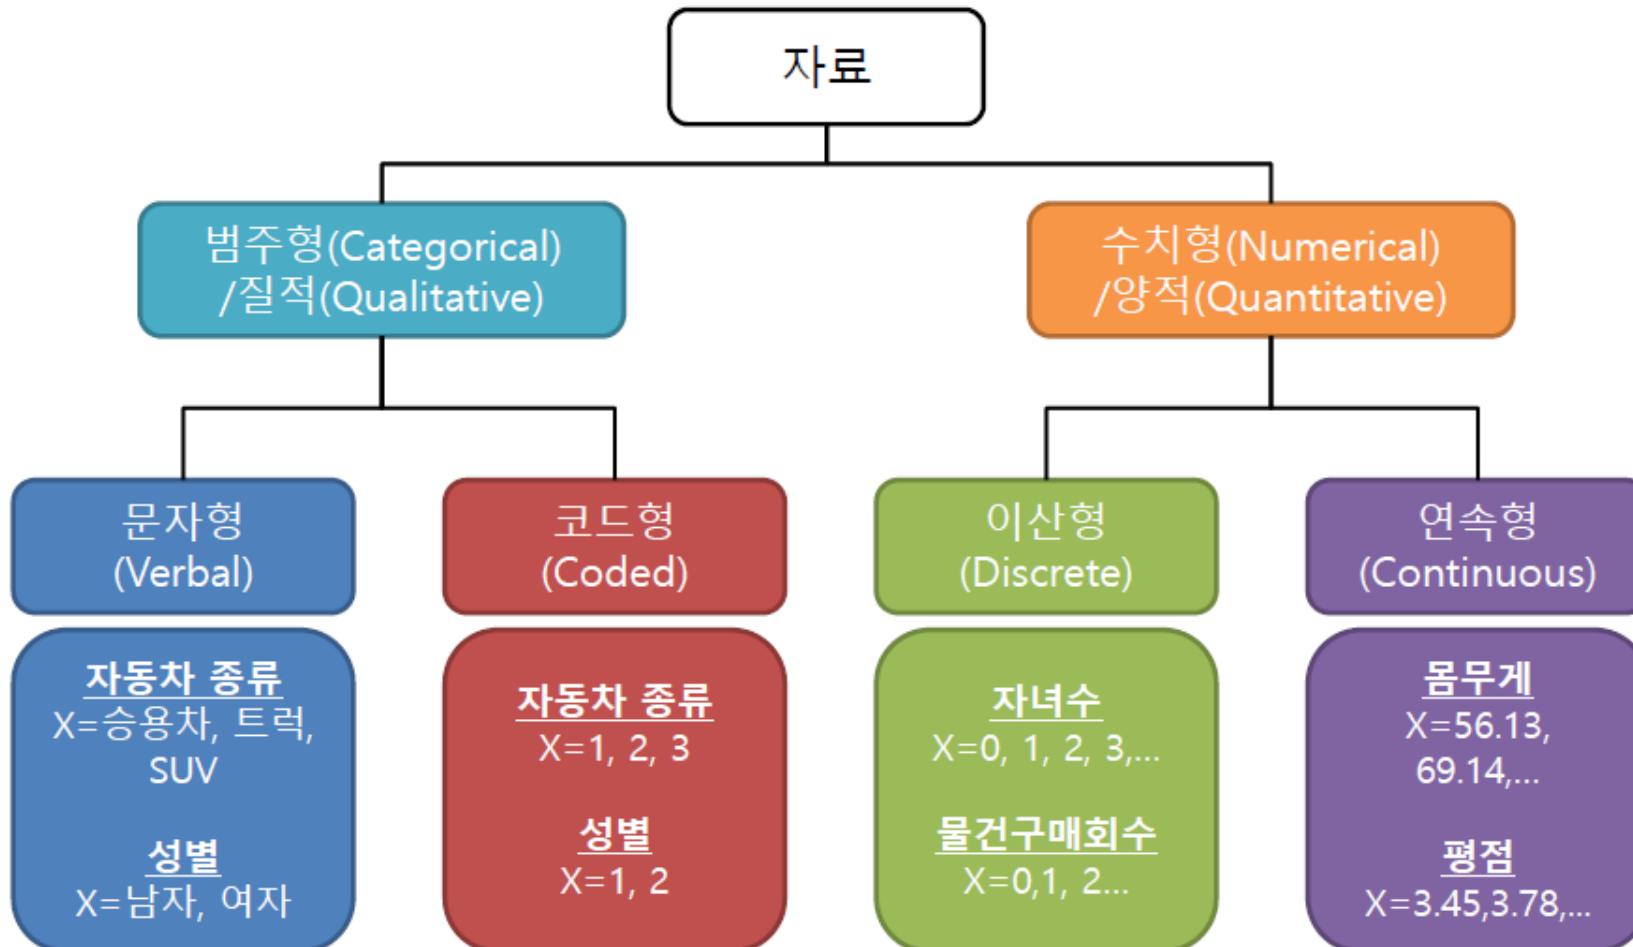
자료와 분석방법

■ 자료의 형태가 중요한 이유

- 자료의 형태와 분석목적에 따라 통계분석이 결정

형태		요약방법	자료정리	그래프	분석방법
범주형	범주형	도표 그래프	도수분포표 분할표	막대도표 원도표	교차분석
범주형	수치형	도표+ 수치	그룹별 평균	그룹별 막대도표 그룹별 상자도표	t-test ANOVA
수치형	수치형	수치 그래프	산술평균 중앙값 조화평균	히스토그램 상자도표 산점도	상관분석 회귀분석 등

자료의 종류



자료의 종류

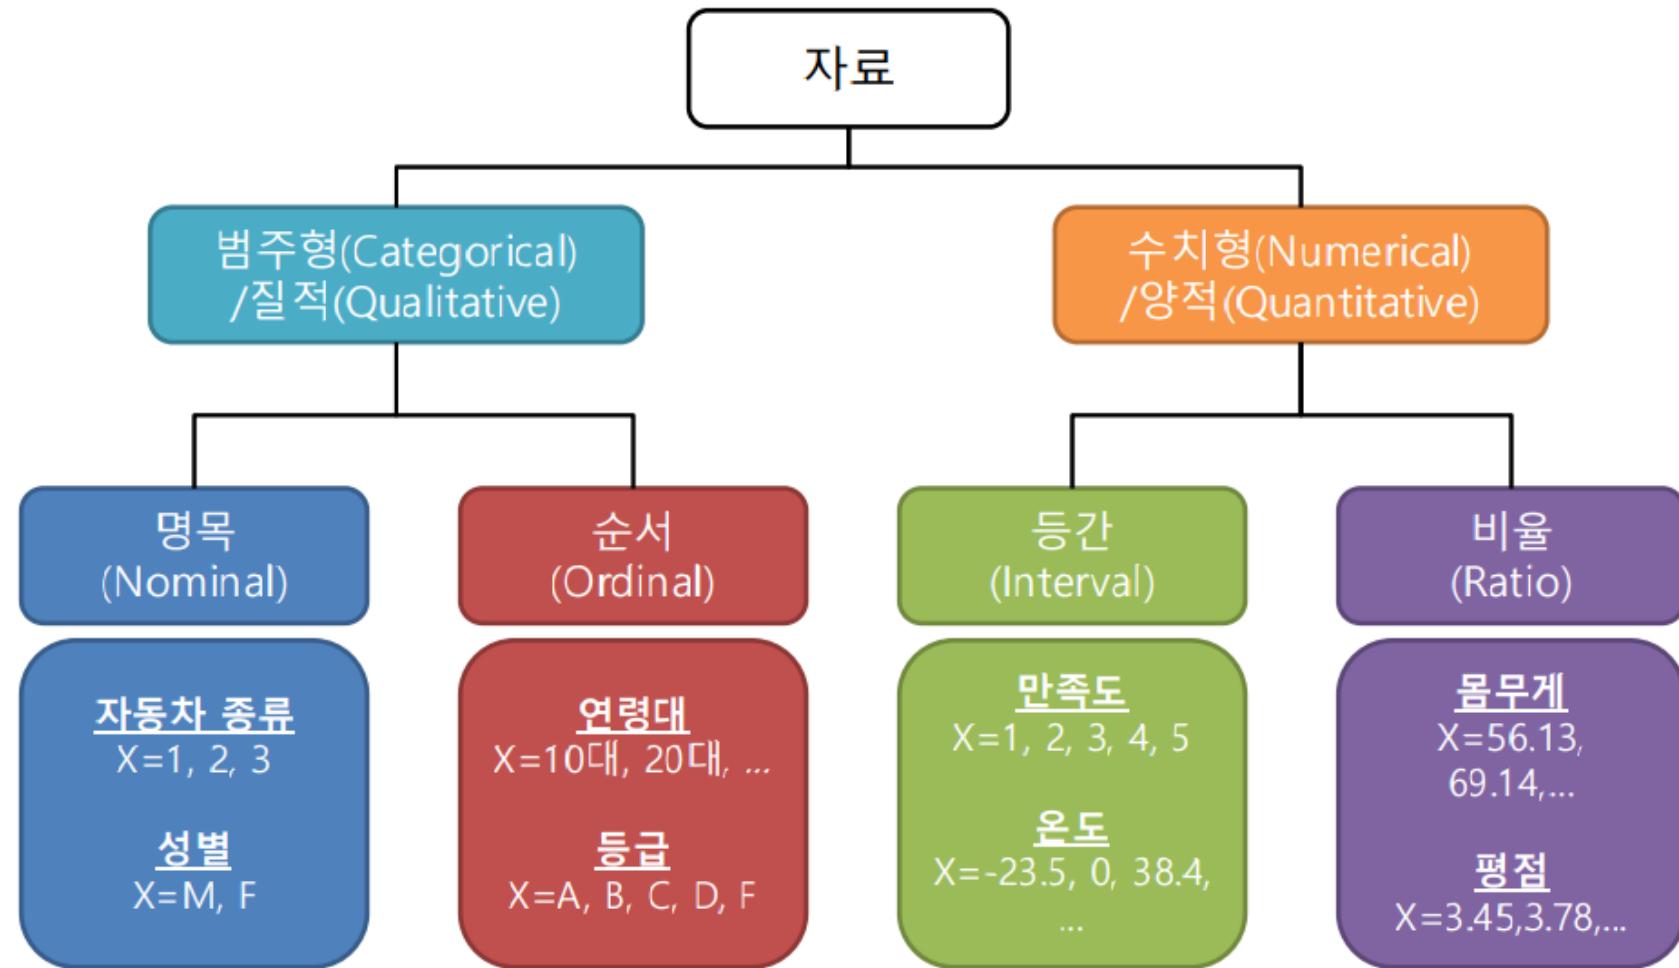
▪ 범주형(질적)자료

- 명목(Categorical), 속성(Attribute) 자료 또는 변수(Variable)
- 몇 개의 특성에 의한 범주를 나누어 코드숫자로 나타낸 자료
 - 예) 성별(남자= 1, 여자=2), 학력(고졸 = 1, 대졸 =2, 대학원졸=3)
- 연산을 할 수 없음 (성별 = 1.5?)

▪ 순서형(연속)자료

- 연속 자료 또는 변수(Continuous variables)
- 이산형 자료(Discrete data): 하나, 둘 셀 수 있는 자료
 - 예) 도시의 아파트 층수, 썩은 치아 수
- 연속형 자료(Continuous data): 구간에서 값을 모두 취할 수 있는 자료
 - 예) 신생아의 키, 세금액수

자료와 척도



자료와 척도

■ 척도(Measurement)의 종류

- 척도: 측정을 하기 위해서 사용한 측정도구
- 예) 키-cm, 몸무게-kg, 성별-M,F, 속도-km/h, 실업률-%

■ 범주형 자료

- 명목자료/척도 (Nominal measurement)
- 측정 대상의 특성을 분류하거나 확인
- 예) 성별, 혈액형, 직업구분

■ 순서자료/척도(Ordinal measurement)

- 측정대상의 특성을 몇 개의 범주로 구분할 뿐만 아니라 그 범주들 사이에 순서관계가 성립하는 경우
- 예) 학력, 학점, 나이대 등
- 예) 좋아하는 과목의 순서: 통계학=1위, 간호학=2위, 수학=3위
- 예) 먹고 싶은 순서대로 순위를 정하세요
- 아이스크림(3), 초콜렛(1), 솜사탕(4), 오렌지 (2)

자료와 척도

■ 수치형 자료

- 등간자료/척도 (Interval measurement)
- 측정 대상의 양적인 차이를 나타내주는 변수
- 절대영점이 존재하지는 않지만 균일한 간격을 두고 분할하여 측정
- 예) 설문지의 설문문항(리커르트 5점), 온도, 아이큐지수

■ 비율자료/척도(Ratio measurement)

- 측정 대상의 양적인 차이를 나타내주는 변수
- 절대영점이 존재하며, 비율계산이 가능
- 예) 시험 점수, 스트레스 점수, 키, 몸무게

이름	연령	연령대
홍길동	21	20대
이길동	29	30대
백두산	35	30대

자료와 척도

■ 리커르트 척도법(Likert Scaling) - 등간자료

- 리커르트 척도법은 여러 개의 항목으로 측정대상의 속성을 측정하고 해당
- 항목에 대한 점수를 합산하여 대상의 속성에 대한 측정치를 얻어내는 척도
- 5점, 7점, 9점
- 설문문항간 타당도 및 신뢰도가 높아야 함

	전혀 그 렇지 않 다	약간 그 렇지 않 다	그렇 지 않 다	보통 이다	그렇 다	약간 그렇 다	매우 그렇 다
	①	②	③	④	⑤	⑥	⑦
8. 이 병원은 약속한 의료서비스(진료, 수술, 면담, 투약, 회진)를 모두 제공한다.							
9. 환자가 어려운 일에 발생했을 때 이 병원의 의료종사자들은 관심을 가져주고 환자를 안심시키기 위해 노력한다.							
10. 이 병원은 믿고 의지할 만하다.							

자료와 척도

■ 서스턴 척도법(Thurstone Scaling) - 등간자료

- 척도의 등간성을 확보할 목적으로 개발된 척도
- 예: 통증을 측정하기 위한 서스턴 척도법
- 1) 옥신거린다(1.5) []
- 2) 뜨끔뜨끔하다(2.5) []
- 3) 바늘로 찌르듯이 아프다(5.7) [O]
- 4) 망치로 때리듯이 아프다(7.5) [O]
- 5) 까무러치게 아프다(8.9) []
- ==> 측정값 : $(5.7+7.5)/2=6.6$

자료와 척도

■ 어의차이척도(Semantic differential scale) - 등간자료

- 양극단에 서로 배타되는 속성을 놓고 평가

■ 다음 고속철도의 서비스 정도에 대한 본인의 느낌을 평가하여 주십시오.

문항1. 빠르다 : ④__ : ③__ : ②__ : ①__ : ②__ : ③__ : ④__ : 느리다

문항2. 소음이 적다 : ④__ : ③__ : ②__ : ①__ : ②__ : ③__ : ④__ : 소음이 많다.

문항3. 좌석이 넓다 : ④__ : ③__ : ②__ : ①__ : ②__ : ③__ : ④__ : 좌석이 좁다

문항4. 청결하다. : ④__ : ③__ : ②__ : ①__ : ②__ : ③__ : ④__ : 청결하지 않다.

■ 고정적합척도(Constant sum scale) - 비율자료

- ex) 자동차를 구매할 때 중요시하는 정도를 100점을 만점으로 분할하여 할당하시오.
- 디자인 (10)점, 배기량(20)점, 색상 (20)점, 상표 (50)점
- 합계 : 100점

자료의 종류

등간척도

비율척도

순서척도

명목척도

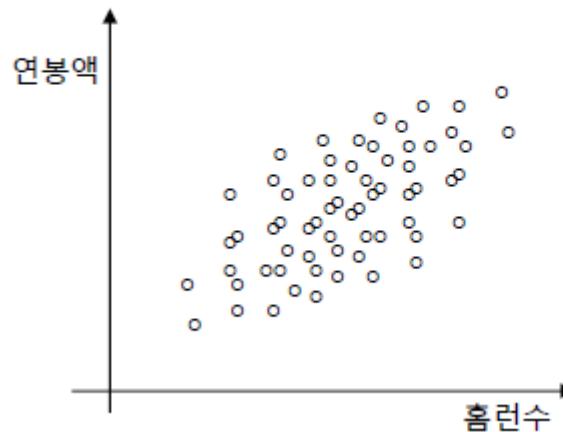
자료의 종류(시간관점)

■ 횡단 자료(Cross-sectional data)

- 한번의 시간에 얻어진 데이터

■ 종단 자료 (Longitudinal data)

- 시계열자료(Time series data)
- 동일한 대상으로부터 여러 시간에 걸쳐 얻어진 데이터
- 예) 주식, 2010-2014년까지의 GDP변화 등



범주형 자료(일변량)

도수분포표

▪ 도수분포표(frequency table)

- 처음 조사된 원자료는 그 자료의 특징 및 분포를 파악하기 어려움
- 데이터 각 값의 출현도수를 세거나 몇 개의 구간으로 나누어 각 구간에 속하는 데이터의 개수를 세어서 정리한 표
- 수집된 자료를 적절한 계급으로 분류, 정리한 표
- 도수(빈도): 범주에 속한 개체의 수
- 상대도수: 범주에 속한 개체의 비율 (%)
- 누적도수: 범주에 속한 개체의 누적비율(%) - 순서자료일 경우
- 질적자료 정리 및 연속변수를 질적자료로 변환해서 사용할 경우에 사용

도수분포표

▪ 범주형 자료의 도수분포표

학점 (사례)

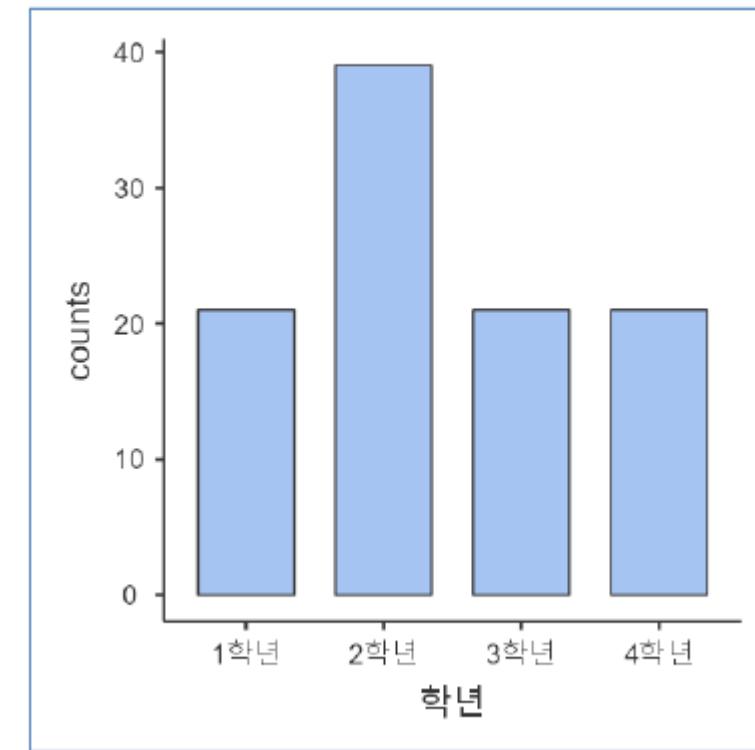
id	성별	분반	학년	몸무게	출석	중간	기말
1	남자	1	1	40	100	87	80
2	여자	2	2	50	100	83	60
3	남자	1	3	56	100	84	60
4	여자	2	4	51	100	73	60
5	남자	1	1	55	100	68	60
6	남자	2	2	61	100	77	50
7	여자	1	3	69	100	40	80
8	여자	2	2	44	100	73	30
9	여자	1	2	66	80	64	40
10	남자	2	2	60	100	66	40
.....							
98	여자	1	3	63	100	56	40
99	남자	1	2	69	100	52	20
100	여자	1	2	66	100	67	70
101	남자	2	2	90	90	54	10
102	여자	1	2	120	100	49	40

도수분포표

▪ 도수분포표와 막대그래프 (Bar chart)

- 누적비율: 순서형일 경우에 사용하면 편리

학점	빈도	비율(%)	누적비율(%)
1학년	21	21%	21%
2학년	39	38%	59%
3학년	21	21%	79%
4학년	21	21%	100%
합계	102	102	102



그래프의 중요성

그래프의 중요성

■ 그래프

- 인간이 지닌 시각적인 인지능력을 활용하여 직관적으로 그 현상을 쉽게 인식하도록 하는 방법
- 통계적인 데이터를 요약하여 시각적으로 그 특징을 나타내는 것

■ 그래프의 문제점

- 그래프는 자료가 가지고 있는 속성뿐만 아니라 강렬한 인상을 주게 되어 확대해석의 오류를 범할 위험이 있음

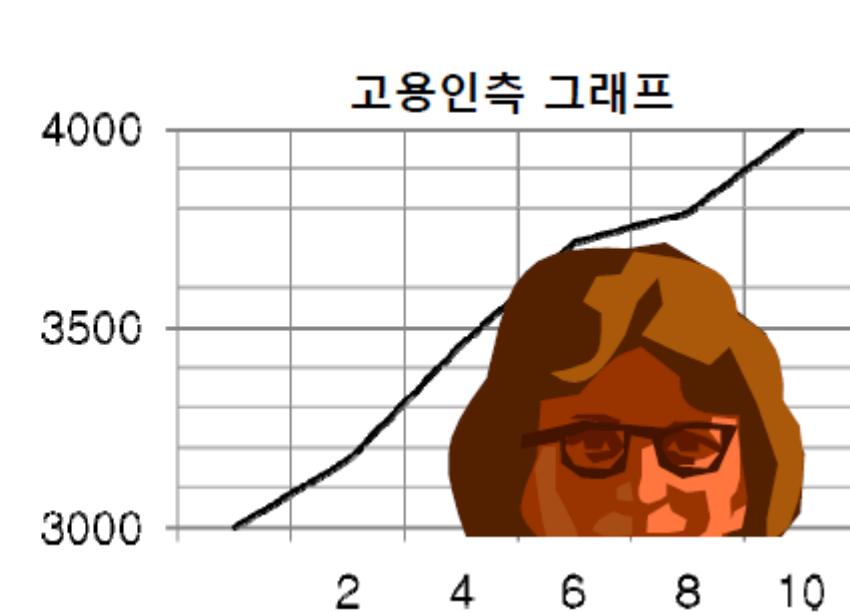
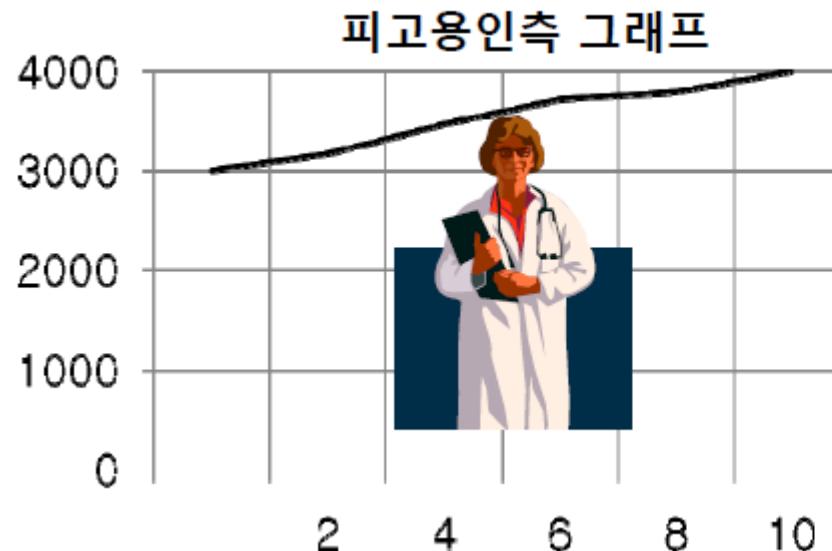
■ 활용

- 그래프를 통해 데이터의 특징 및 자료의 이상치를 점검하여 이후의 통계분석에 대비함

올바른 그래프 그리는 법

■ 올바른 그래프의 작성

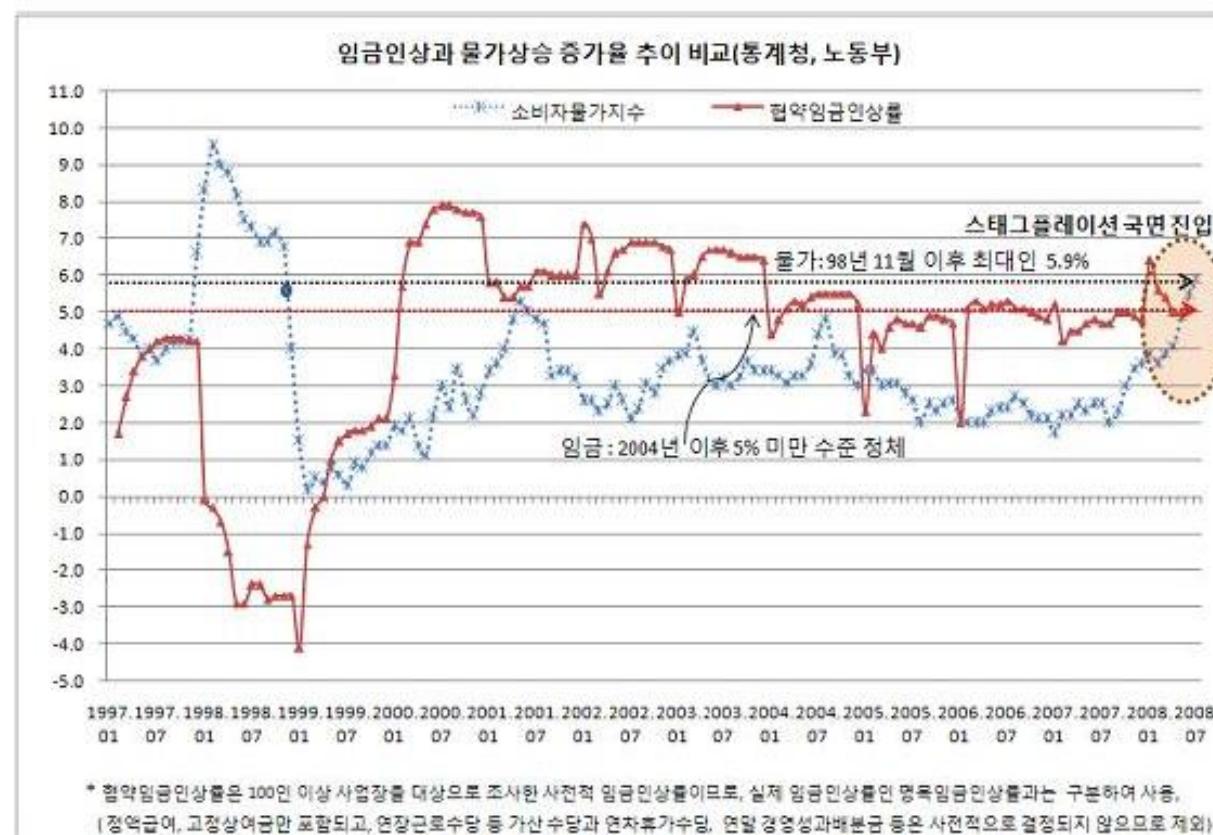
- 그래프에 적합한 제목
- 자료의 출처, 표본의 크기, 수집방법을 나타냄
- 축에 대한 제목을 명확히 함
- 도수비율, 퍼센트 등이 0에서 시작하는지 점검
- 변수의 측정단위가 표시되어야 함



올바른 그래프 그리는 법

- γ축 단위가 0이 아닐 때

- 단순히 하나의 수치만 적지 말고 비교되는 자료를 동시에 포함
 - 물가변동에 대한 임금상승율의 변화를 객관적으로 볼 수 있음



범주형 자료(다면량)

범주형자료(2개) - 분할표

▪ 분할표(Contingency table)

- 관측치를 몇 개의 범주로 분할하여 그 해당도수로 자료를 정리해 놓은 표
- 다변량 자료: 범주형 변수가 2개 일 때
- 비율을 표시하는 방법이 중요(행, 열, 전체): 분석목적에 따라 비율표시
- 분할표를 이용한 통계분석 : 교차분석(chi-square)

일원분할표

대조군	처리군	합계
60	40	100

일원분할표

생존	사망	합계
50	50	100

이원분할표

	대조군	처리군	계
생존	40	10	50
사망	20	30	50
계	60	40	100

사전설계 분할표

▪ 사전(실험)설계(코호트 연구)일 때

- 사전에 그룹의 수를 결정해서 연구할 때 -> 해석: 그룹에 따른 차이
- 코호트 연구
 - 예) 비타민과 감기에 대한 연구를 하기 위해, 비타민을 투여할 실험군과 가짜약을 투여할 대조군으로 사전에 구분하여 연구
- 실험군과 대조군에 따른 차이를 검정: 교차분석(동질성 검정)
- 비율기준: 그룹별 자료수

사후

그룹	감기발병		합계
	유	무	
실험군 (비타민)	17 (34.0%)	33 (66.0%)	50 (100.0%)
대조군 (Placebo)	38 (76.0%)	12 (24.0%)	50 (100.0%)
합계	55 (55.0%)	45 (45.0%)	100 (100.0%)

사전설계 분할표

- 감기발병을 기준으로 했을 경우: 실험군의 자료수 증가할 때

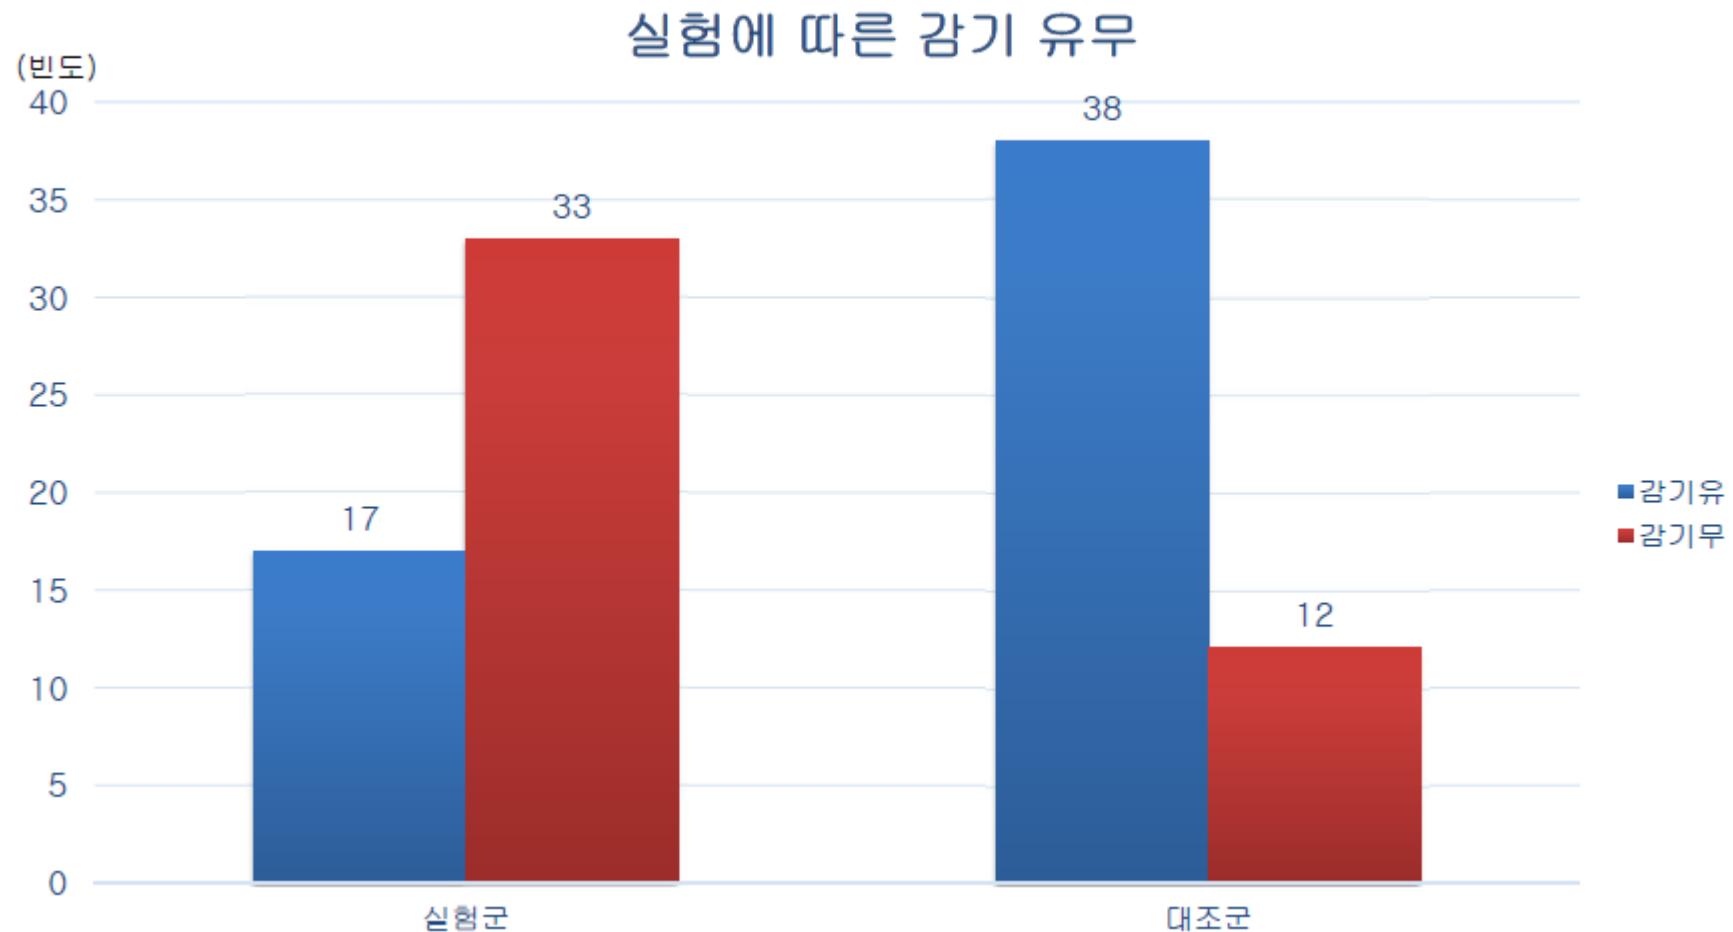
그룹	감기발병		합계
	유	무	
실험군 (비타민)	170 (34.0%)	330 (66.0%)	500 (100.0%)
대조군 (Placebo)	38 (76.0%)	12 (24.0%)	50 (100.0%)
합계	55 (37.8%)	45 (62.2%)	100 (100.0%)

변화없음

그룹	감기발병		합계
	유	무	
실험군 (비타민)	170 (81.7%)	330 (96.5%)	500 (91.0%)
대조군 (Placebo)	38 (18.2%)	12 (3.5%)	50 (9.0%)
합계	208 (100.0%)	342 (100.0%)	550 (100.0%)

자료수에 따라 변화

사전설계 분할표



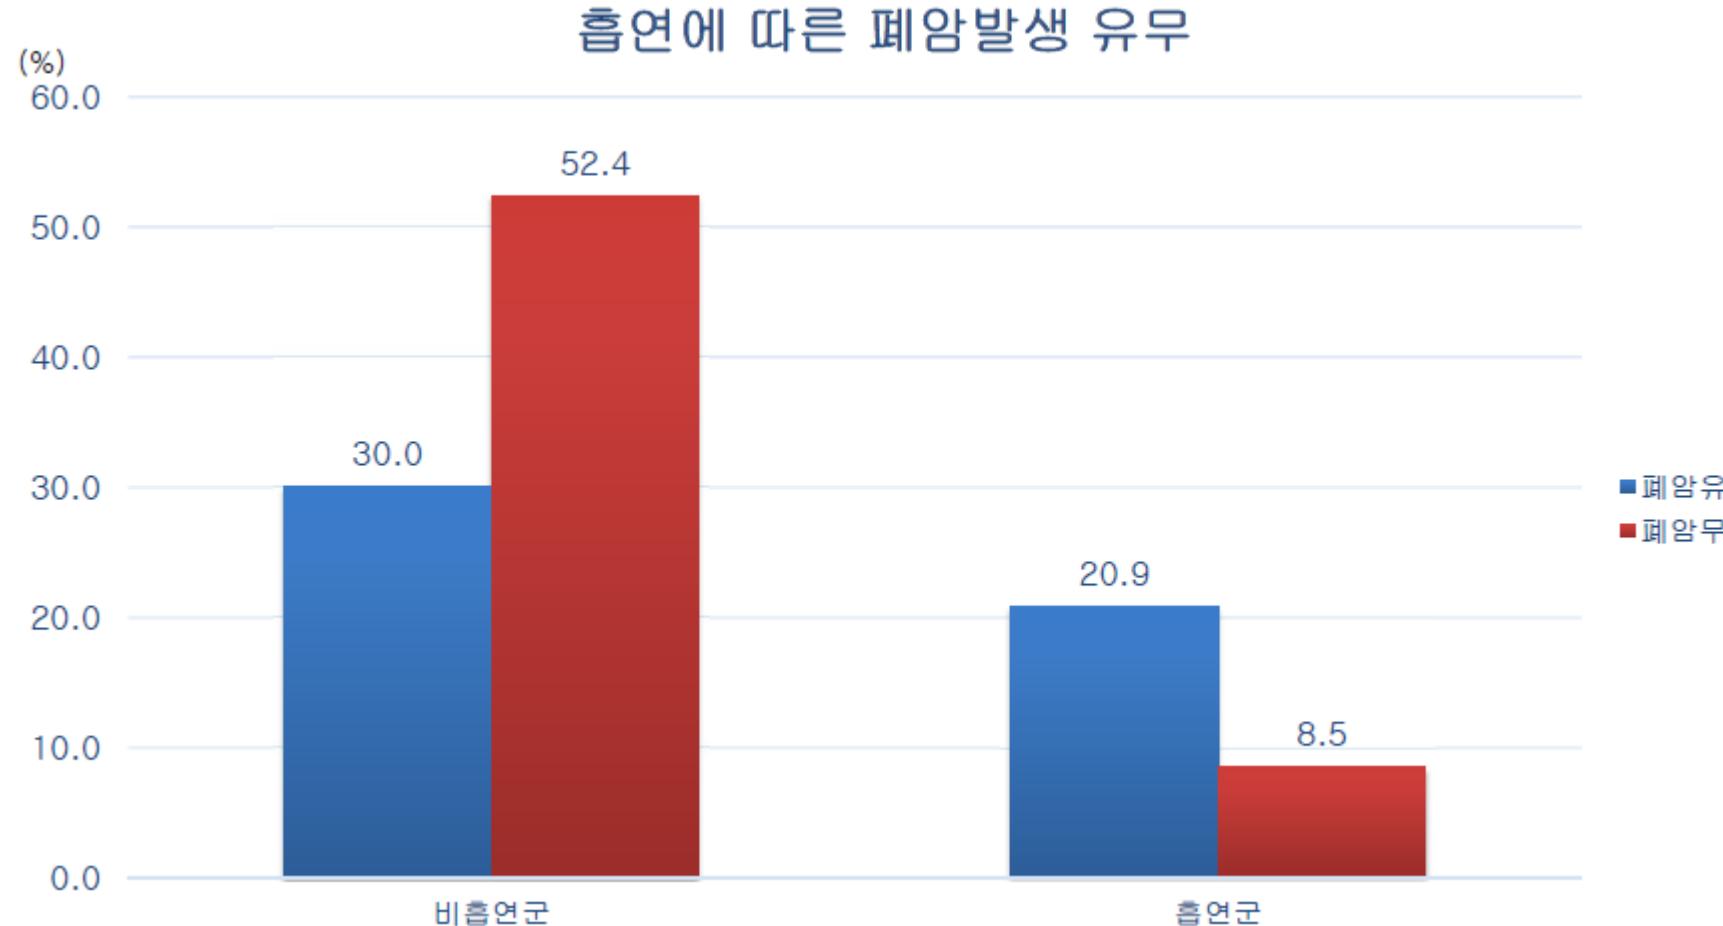
사후설계 분할표

■ 사후설계(사례대조) 분할표

- 사전에 그룹의 인원수를 정하지 못하고 사후의 결과를 토대로 연구할 때 -> 해석: 두 변수간의 관련성
- 예) 흡연이 폐암과 연관이 있는지를 연구하기 위해 흡연자와 비흡연자를 대상으로 폐암발생여부를 사후에 조사
- 폐암과 흡연간의 관련성을 검정: 교차분석(독립성검정)
- 비율기준: 전체 자료수

		사전					합계	
		흡연						
사후	폐암	비흡연군	장기금연군	단기금연군	재흡연군	흡연군		
	무	170,867 (52.0%)	51,690 (15.7%)	46,598 (14.2%)	29,178 (8.9%)	27,784 (8.5%)	326,117 (99.3%)	
	유	723 (0.2%)	370 (0.1%)	497 (0.2%)	319 (0.1%)	504 (0.2%)	2,413 (0.7%)	
	합계	171,590 (52.2%)	52,060 (15.8%)	47,095 (14.4%)	29,497 (9.0%)	28,288 (8.6%)	328,530 (100.0%)	

사후설계 분할표



연습문제

- 07. 온라인게임.csv를 이용하여 범주형 자료를 분석하세요.
- Q1. 성별: 1=남자, 2=여자
- Q2. 학력: 1=고등학생이하, 2=고등학교졸업, 3=대학생, 4=대학생 이상
- Q3. 성별(sex)의 둑수분포표, 막대그래프(덧수), 막대그래프(비율),
- Q4. 학력(school)의 둑수분포표, 막대그래프(덧수), 막대그래프(비율),
- Q5. 성별(sex)과 학력(school)의 이원분할표, 막대그래프

수치형 자료(일변량)

수치형 자료

■ 수치형 자료 정리

- 일반적으로 연속자료의 특성을 시각적으로 파악하기 보다는 숫자로 기술
- 분포의 특성을 숫자로 표현하는 법
- 지능지수 : IQ, 경제현상:GDP, 불쾌지수 등
- 중심위치와 산포경향

■ 중심위치(central location)

- 관찰된 자료들이 어디에 집중되어 있는가를 나타냄
- 종류 : 산술평균, 중앙값, 최빈값, 기하평균, 조화평균, 가중평균

■ 산포경향 (변동)

- 자료가 중심위치로부터 어느 정도 흩어져 있는가를 나타냄
- 자료가 평균으로부터 떨어진 평균 차이(거리)
- 종류 : 범위, 편차, 분산, 표준편차

수치형 자료

▪ S대학 기초통계 수강생의 몸무게 분석

(단위: kg)

40	70	46	52	55	56	62	71	53	62
50	44	63	45	62	48	57	58	57	56
56	66	56	57	67	50	68	41	60	59
51	60	52	55	49	68	54	58	59	50
55	56	48	67	49	53	62	48	53	61
61	72	57	52	52	58	59	69	47	64

(산술) 평균 (Mean)

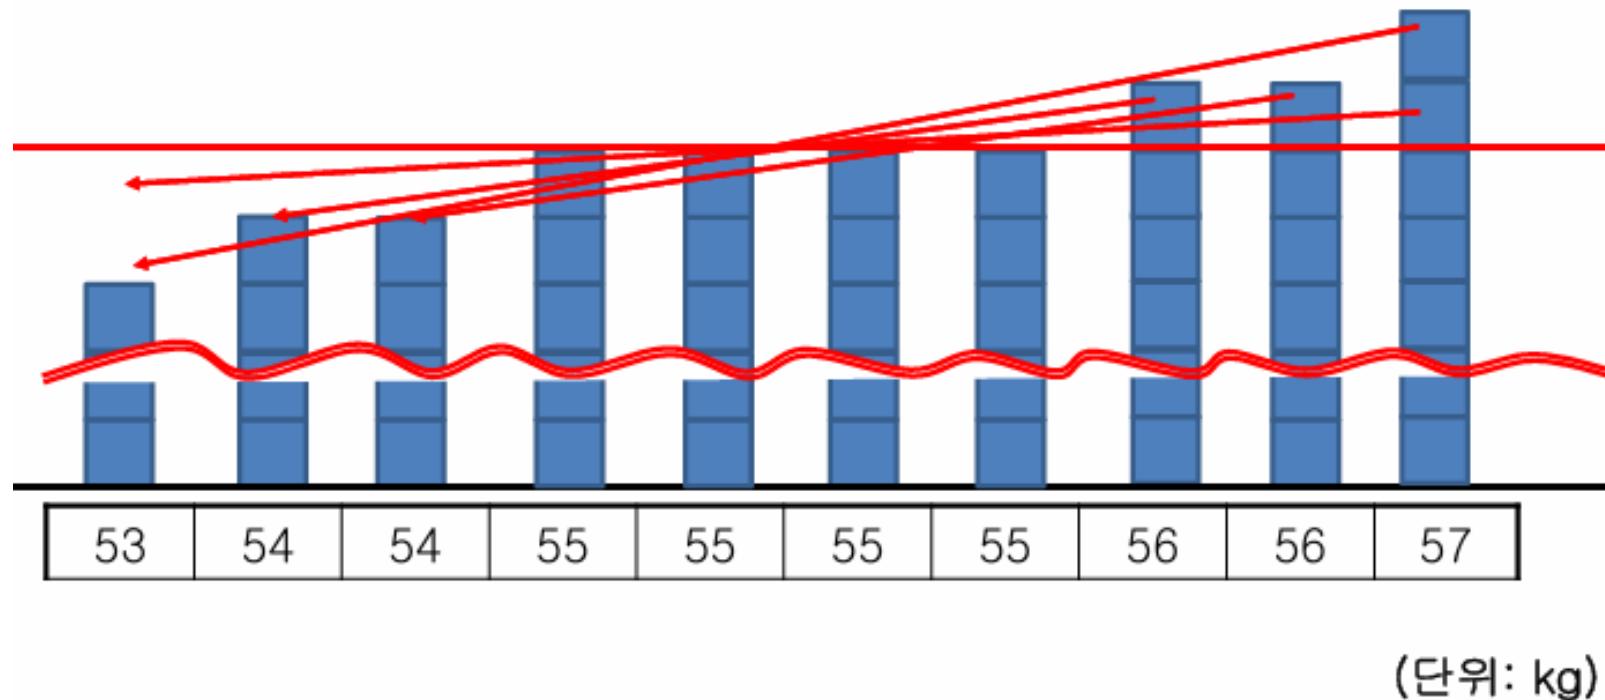
▪ 평균

- 균등하게 나누다
- 중심위치(central location)
- 자료의 중심적인 경향을 나타내는 수치(무게중심)
- 관찰된 자료들이 어디에 집중되어 있는가를 나타냄
- 전체 자료를 대표
 - 예) 학생들의 평균 국어점수, S대학 통계 수강생의 몸무게 분석

(산술) 평균 (Mean)

▪ 평균

- 균등하게 나누다
- S대학 경영통계 수강생의 몸무게 분석



(산술) 평균 (Mean)

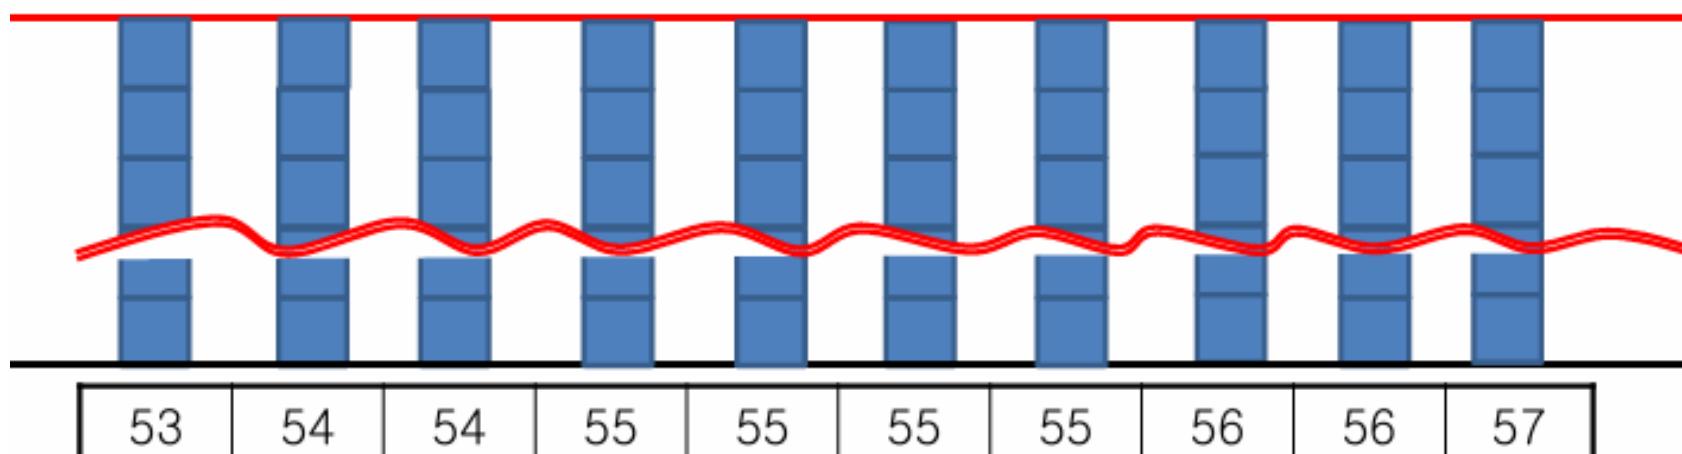
▪ 평균

- 균등하게 나누다
- S대학 경영통계 수강생의 몸무게 분석

$$\bar{x} = \frac{1}{n} (x_1 + x_2 + \dots + x_n) = \frac{1}{n} \left(\sum_{i=1}^n x_i \right)$$

$$= \frac{1}{10} (53 + 54 + \dots + 56 + 57)$$

$$= 55$$



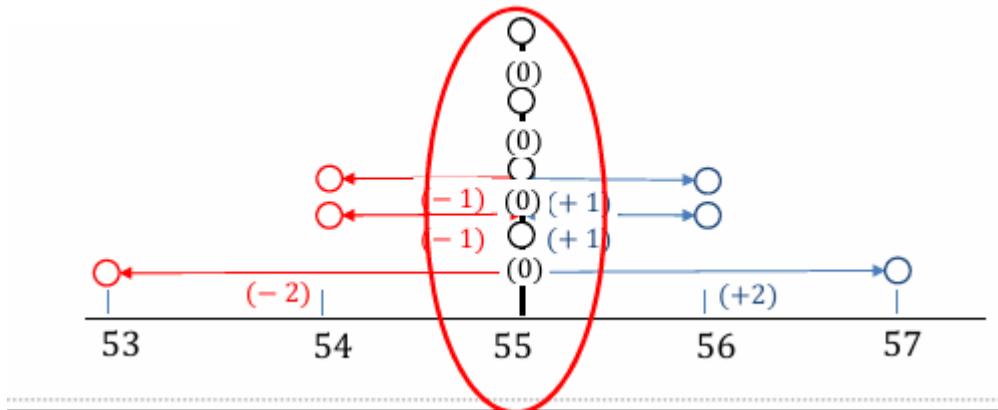
(산술) 평균 (Mean)

▪ 평균

- 자료의 중심적인 경향을 나타내는 수치(무게중심)
- 중심위치(central location): 분포상의 무게 중심
- 중심위치: 평균을 중심으로 왼쪽 자료와 오른쪽 자료를 다 더하면 0
- 편차: $\sum (x_i - \bar{x}) = 0$

$$(53 - 55) + (54 - 55) + \dots + (56 - 55) + (57 - 55) = 0$$

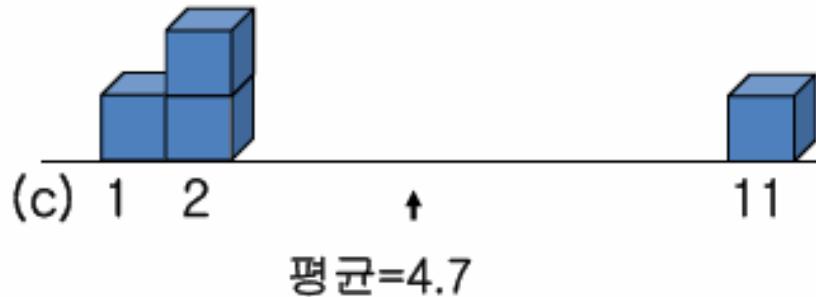
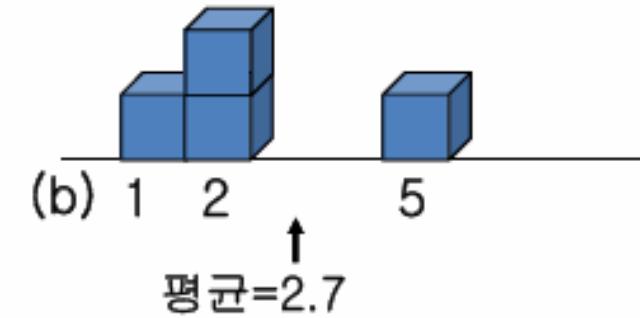
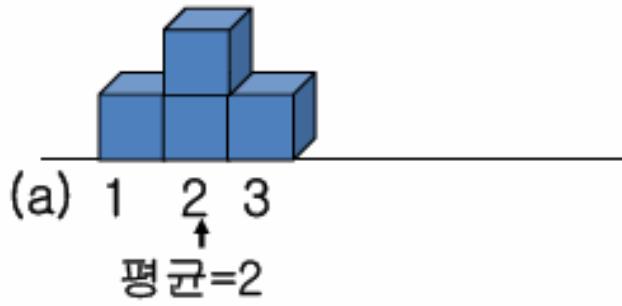
- 관찰된 자료들이 어디에 집중되어 있는가를 나타냄
- 전체 자료를 대표



(산술) 평균 (Mean)

▪ 산술평균의 문제

- 이상치(outlier)에 민감하게 반응함
- 보완: 중앙값, 최빈값, 절사평균



중앙값(Median)

- 자료를 크기 순으로 나열할 때 가장 가운데 오는 값

$$\tilde{x} = \frac{x_{n+1}}{2}$$

- 특징

- 이상치의 영향을 받지 않음
- 중앙값을 중심으로 좌우 분포 면적이 같음
- 원데이터를 크기 순서대로 재 배열
- 짝수일 경우에는 가운데 두개 값의 평균

53, 54, ..., 55, 55, ..., 56, 57
1 2 6 7 9 10

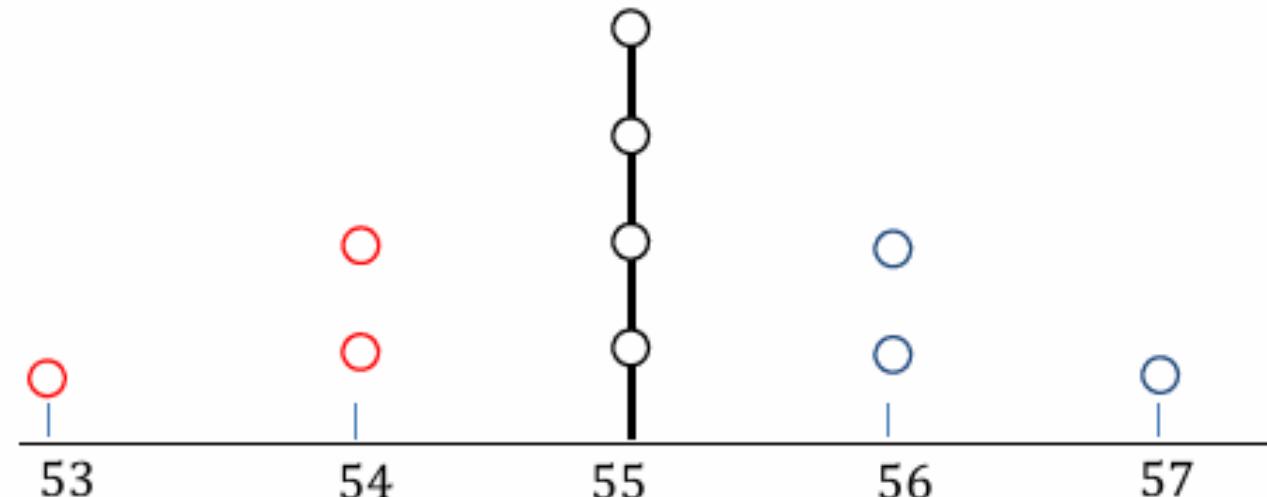
$$\tilde{x} = \frac{55 + 55}{2} = 55.5$$

최빈값(Mode)

■ 자료 중 발생빈도가 가장 높은 값

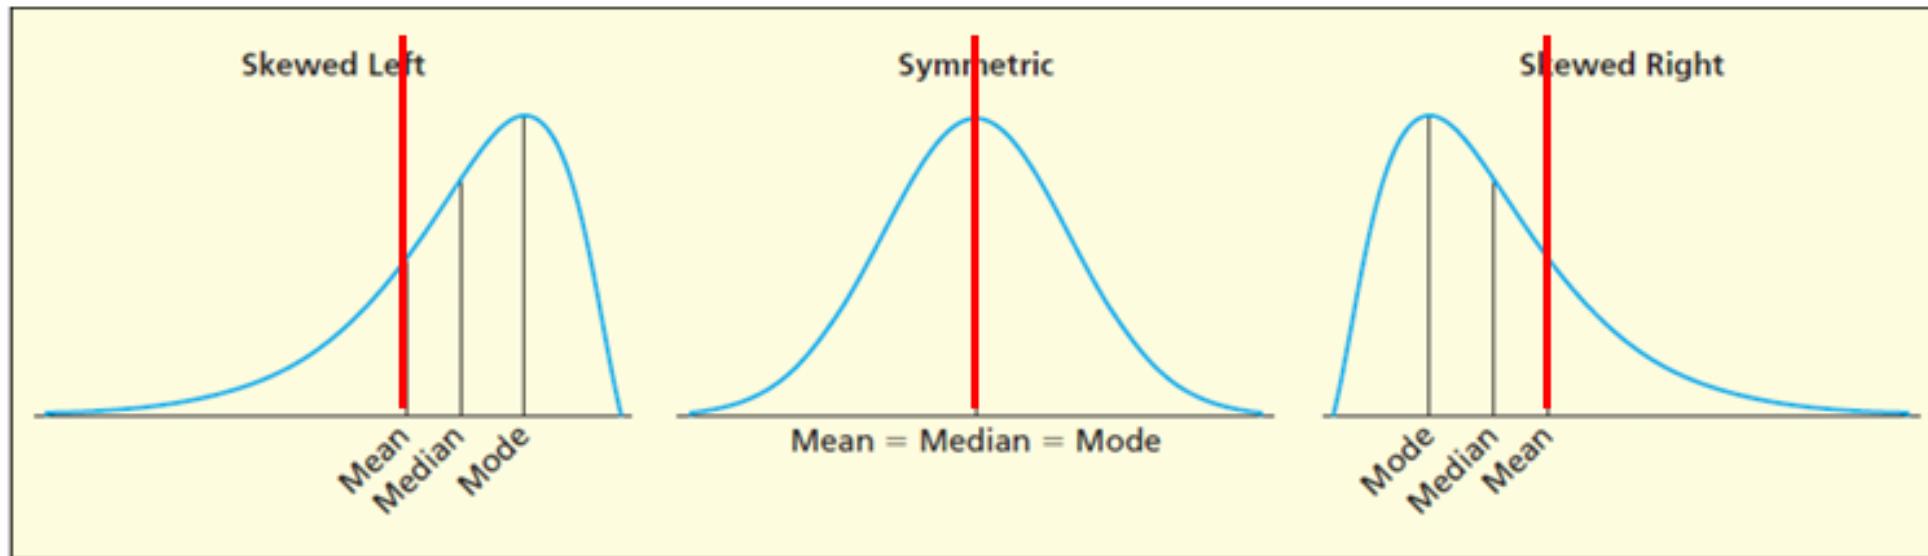
- 빈도수에 의해 산출
- 유일하지 않을 수도 있음

몸무게	빈도
53	1
54	2
55	4
56	2
57	1



중심위치의 모양

- 자료의 분포와 평균, 중앙값, 최빈값과의 관계

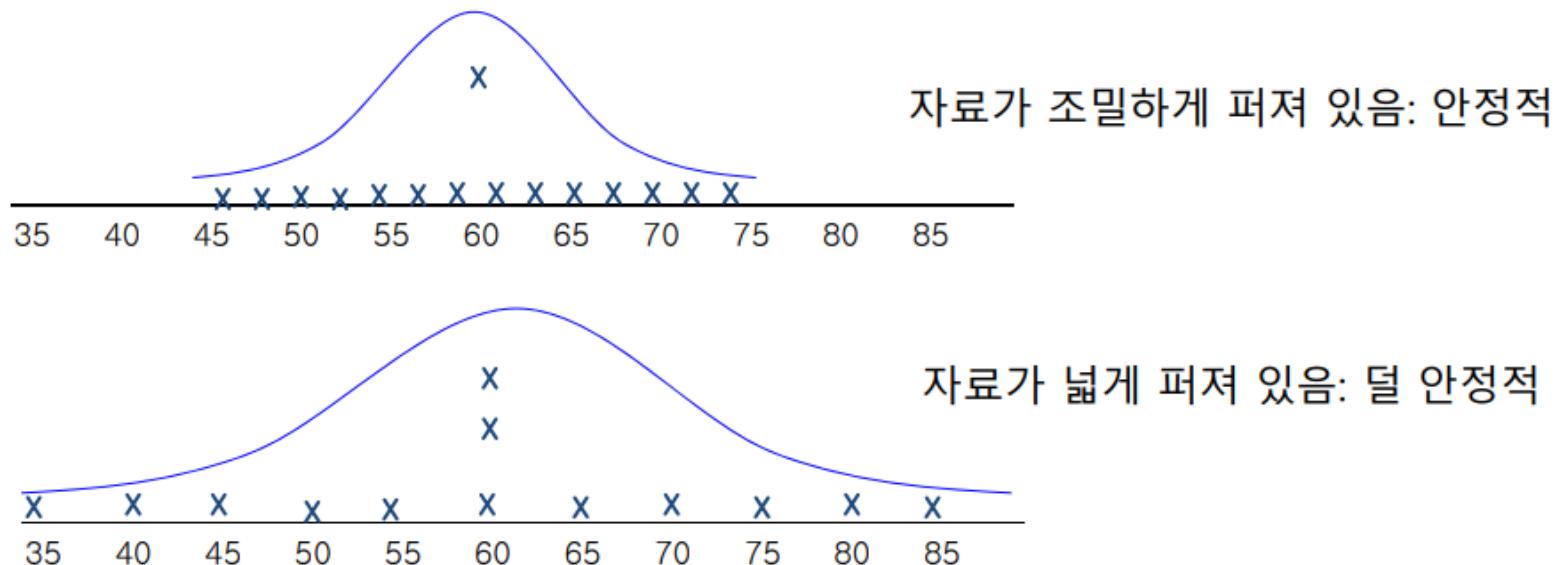


산포(변동)

산포

■ 산포 (Dispersion, 변동)

- 자료가 중심위치로부터 어느 정도 흩어져 있는가를 나타냄
- 자료가 평균으로부터 떨어진 평균 차이(거리)
- 수치 자료의 특징을 정리할 때 평균과 같이 제공
- 종류 : 범위, 4분위, 편차, 분산, 표준편차
- 중심위치(평균)이 얼마나 안정적인지에 대한 정보



범위

▪ 범위(Range)

- 자료의 최대값에서 최소값을 뺀 것
- 두 환자의 측정시간에 따른 맥박수 분포

$$R = X_{\max} - X_{\min}$$

	아침	점심	저녁
환자A	72	76	74
환자B	72	91	59

$$R_A = 76 - 72 = 4$$

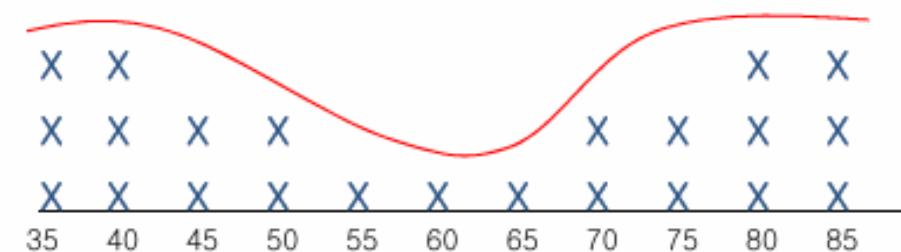
$$R_B = 91 - 59 = 32$$

범위

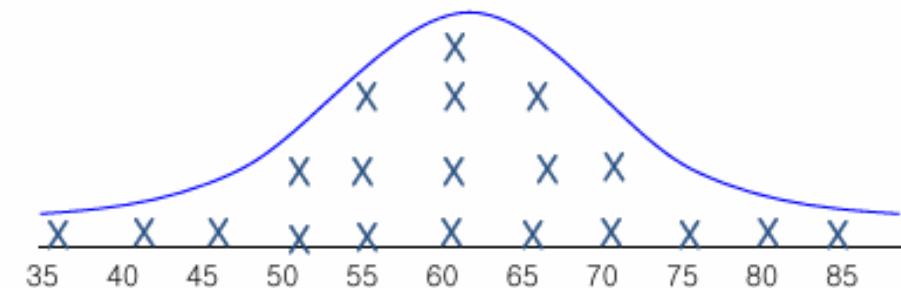
▪ 범위(Range)의 문제

- 같은 범위 값의 서로 다른 분포
- 최대값과 최소값에 의해서만 영향 받음
- **분포의 대표값으로 사용 못함**

■ 자료1



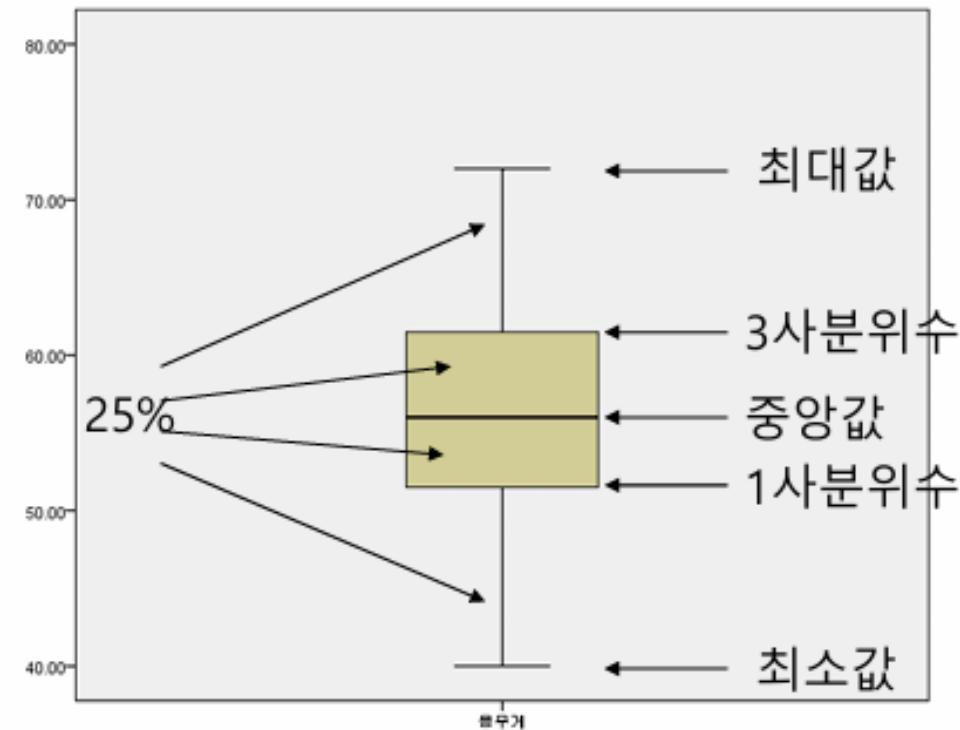
■ 자료2



사분위

▪ 사분위(Interquartile-Range)

- 자료를 동일한 비율로 4등분
- 자료를 순서대로 정렬
- 제1사분위수(Q1): 25%
- 제2사분위수(Q2): 50%
- 제3사분위수(Q3): 75%
- 제4사분위수(Q4): 100%
- 상자도표(box plots)에서 사용
- 이상치(Outlier) 제거시 사용



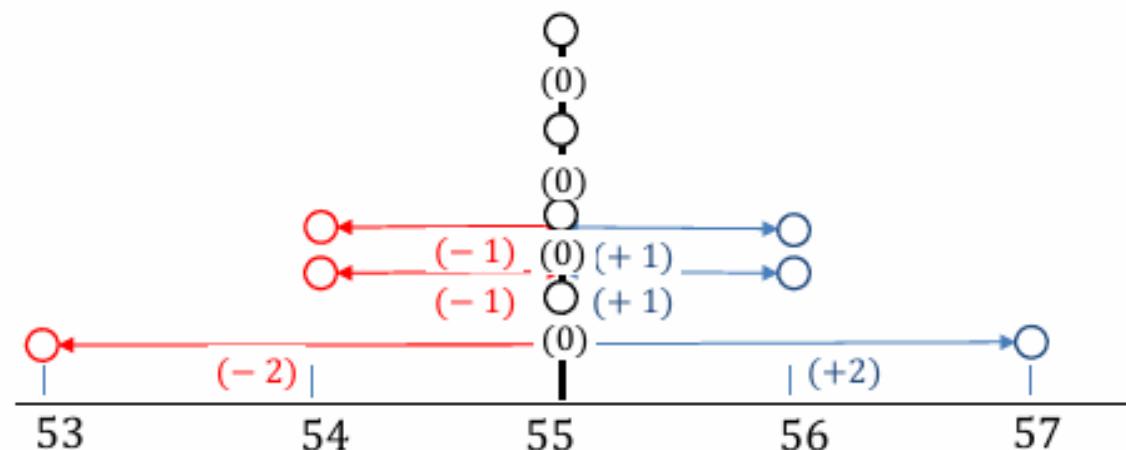
편차

▪ 편차

- 데이터가 평균으로부터 얼마나 떨어져 있는지를 나타내는 지표
- 평균을 중심으로 왼쪽 자료와 오른쪽 자료를 다 더하면 0

$$\sum (x_i - \bar{x}) = 0$$

$$(53 - 55) + (54 - 55) + \dots + (56 - 55) + (57 - 55) = 0$$



분산과 표준편차

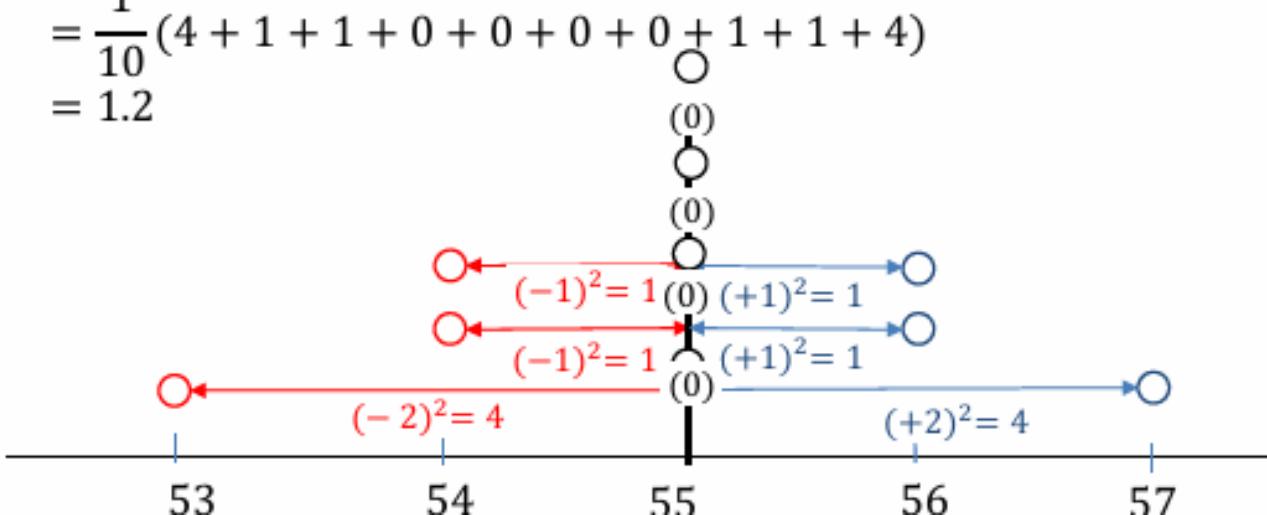
▪ 분산(variance)

- 편차 -> 분산: “-”를 없애주기 위해
- 자료가 평균을 중심으로 얼마나 광범위하게 분포하고 있는 가를 하나의 수치로 나타낸 통계량

$$var(\bar{x}) = \sigma^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$$

$$\frac{1}{n} \sum (x_i - \bar{x})^2 = \frac{1}{10} (53 - 55)^2 + (54 - 55)^2 + \dots + (56 - 55)^2 + (57 - 55)^2$$

$$\begin{aligned} &= \frac{1}{10} (4 + 1 + 1 + 0 + 0 + 0 + 0 + 1 + 1 + 4) \\ &= 1.2 \end{aligned}$$



분산과 표준편차

▪ 표준편차(Standard Deviation)

- 분산을 원 자료의 측정단위로 다시 전환하기 위해
- 자료가 평균으로부터 떨어진 평균 차이(거리)

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{n} \sum (x_i - \bar{x})^2}$$

$$\sigma = \sqrt{1.2} = 1.1$$

- 편차 → 분산 → 표준편차
- $\sum (x_i - \bar{x}) = 0 \rightarrow \frac{1}{n} \sum (x_i - \bar{x})^2 = \sigma^2 \rightarrow \sigma = \sqrt{\sigma^2}$

분산과 표준편차

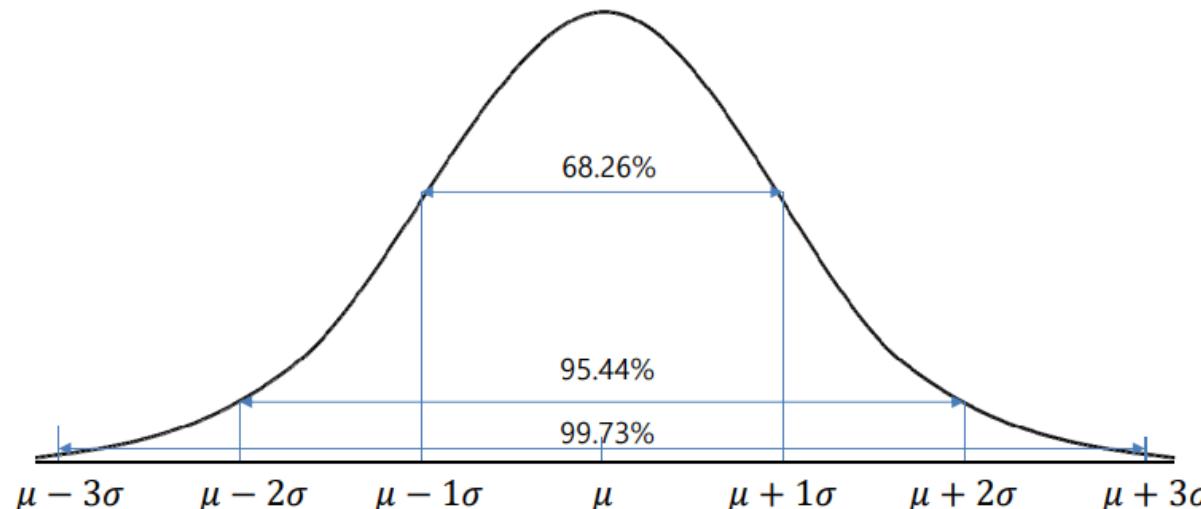
■ 표준편차의 중요성

- 자료의 분포와 변동에 대한 중요한 정보를 제공

- 통계학의 중요한 규칙과 연결

- Empirical Rule (경험적 법칙)

- $k = 1$, 68.26% 이상의 데이터가 $\mu \pm 1\sigma$ 사이에 있음
- $k = 2$, 95.44% 이상의 데이터가 $\mu \pm 2\sigma$ 사이에 있음
- $k = 3$, 99.73% 이상의 데이터가 $\mu \pm 3\sigma$ 사이에 있음



표준화

■ 표준화(standardization)

- 측정단위 등과 관계없이 자료를 표준화 시킨 값
- z값으로 변환된 자료

$$z_i = \frac{x_i - \bar{x}}{s}$$

- 사례) $\bar{x} = 50kg$, $s = 5kg$ 일 때 40, 65kg인 자료의 표준화된 값은?

$$z = \frac{40 - 50}{5} = -2 \quad z = \frac{65 - 50}{5} = 3$$

- 모든 자료가 $\bar{z} = 0$, $s_z = 1$ 로 표준화 됨 → 절대 비교가 가능

변동계수(Coefficient of Variation)

- 측정단위가 다르거나 자료 값의 차이가 큰 경우에 사용

$$CV = \frac{s}{\bar{x}} \times 100$$

- (예) 유치원 여자 어린이들의 몸무게와 50대 주부의 몸무게 분포 비교

	\bar{x}	s	CV
어린이	20	8	0.40
50대주부	55	13	0.23

- 키(cm)와 몸무게(kg)

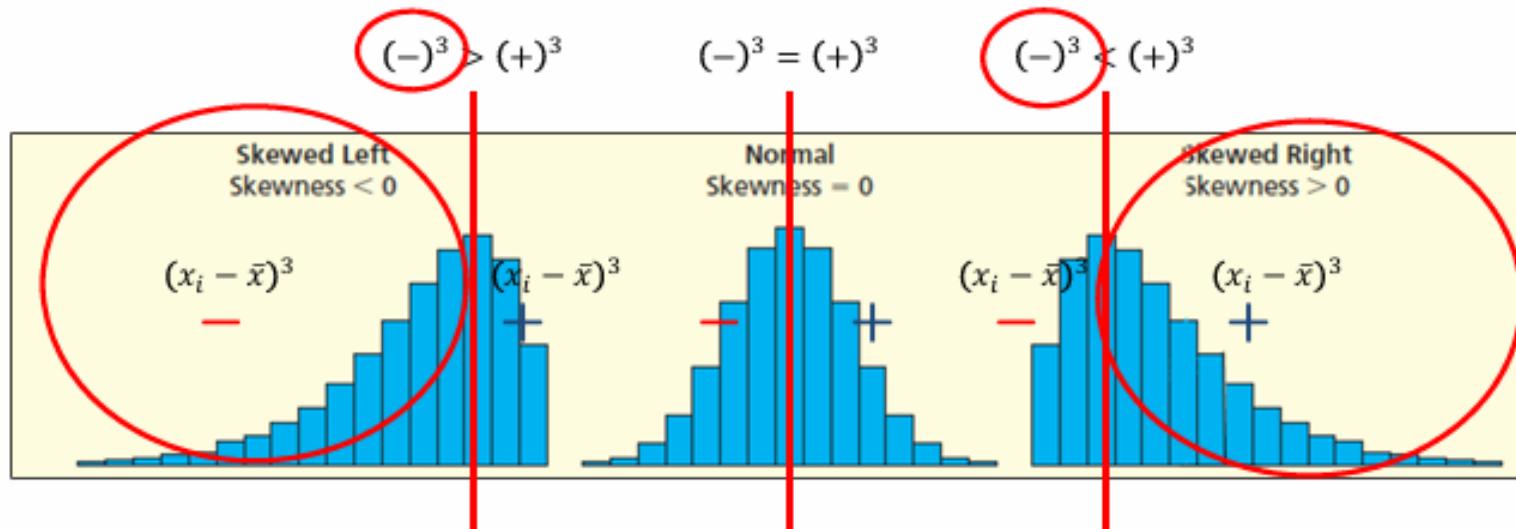
	\bar{x}	s	CV
키	175	15	0.09
몸무게	73	9	0.12

분포 형태

■ 자료의 분포 형태

- 왜도(skewed): 자료가 평균을 중심으로 대칭인지-> 정규분포인지 확인
- 자료에 이상점이 있는지 점검

$$\sqrt{b_1} = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3$$

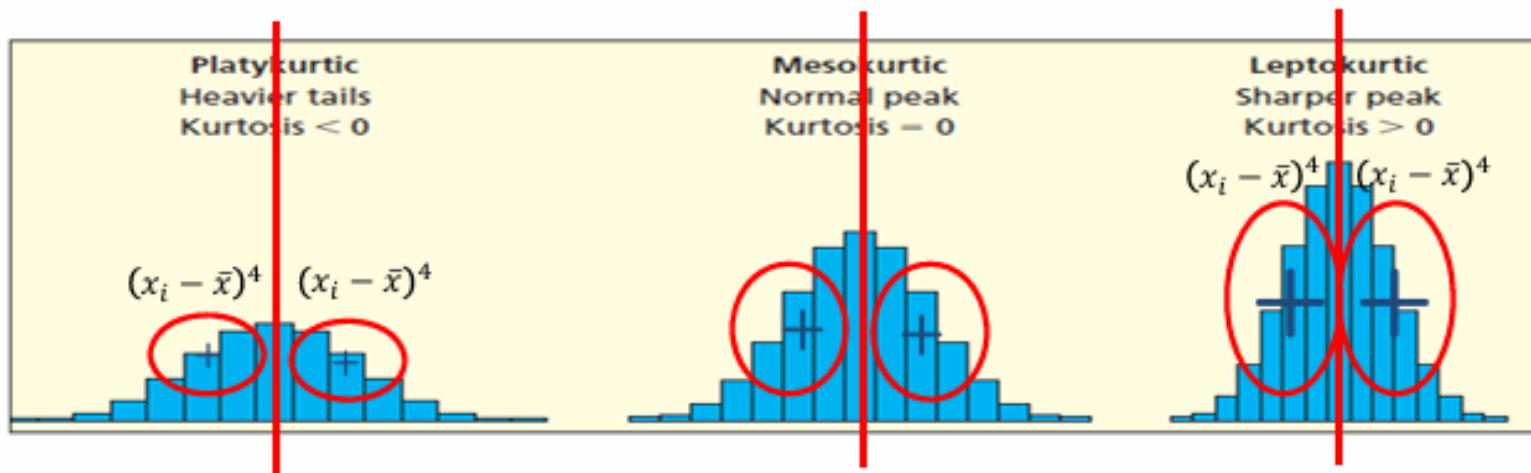


분포 형태

■ 자료의 분포 형태

- 첨도(kurtosis): 양쪽 꼬리가 얼마나 두터운지
- 자료에 이상점이 있는지 점검

$$\sqrt{b_2} = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^4 - 3$$



수치형 자료의 범주화

수치형 자료의 범주화

■ 계급(bin)의 수 결정 규칙

- Sturges' Rule

$$k = 1 + 3.3\log(n)$$

- 자료의 개수 : $n = 60$
- 계급의 수 : $1 + 3.3 \log(60) = 6.87 \approx 7$
- 자료의 최대값과 최소값: $72 - 40 = 32$
- 계급의 폭 : $\frac{32}{7} = 4.57 \approx 5$

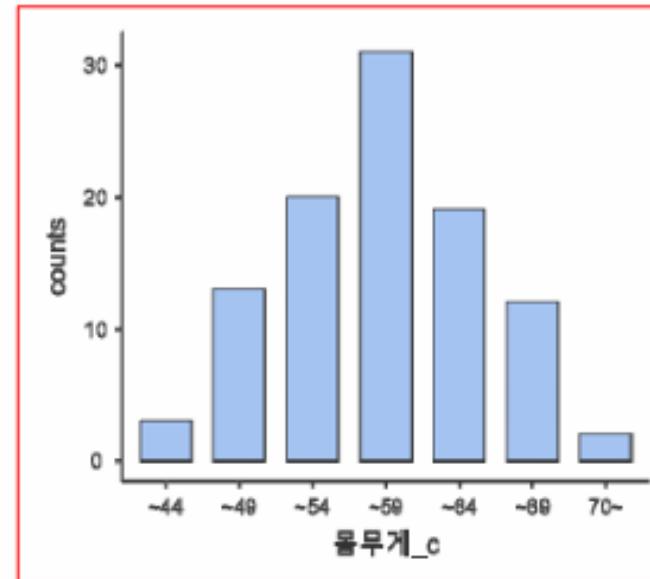
■ 자료의 특성을 고려해 분석자가 결정(^^)

- 같은 간격으로 하는 것이 기본
- 소득 등 특정 구간에 자료가 많을 경우에는 특성을 고려해 구간 배분 가능

수치형 자료의 범주화

- 범주형 자료로 변환 후 정리

몸무게_범주	숫자	%	누적%
~44	3	3	3
~49	13	13	16
~54	20	20	36
~59	31	31	67
~64	19	19	86
~69	12	12	98
70~	2	2	100



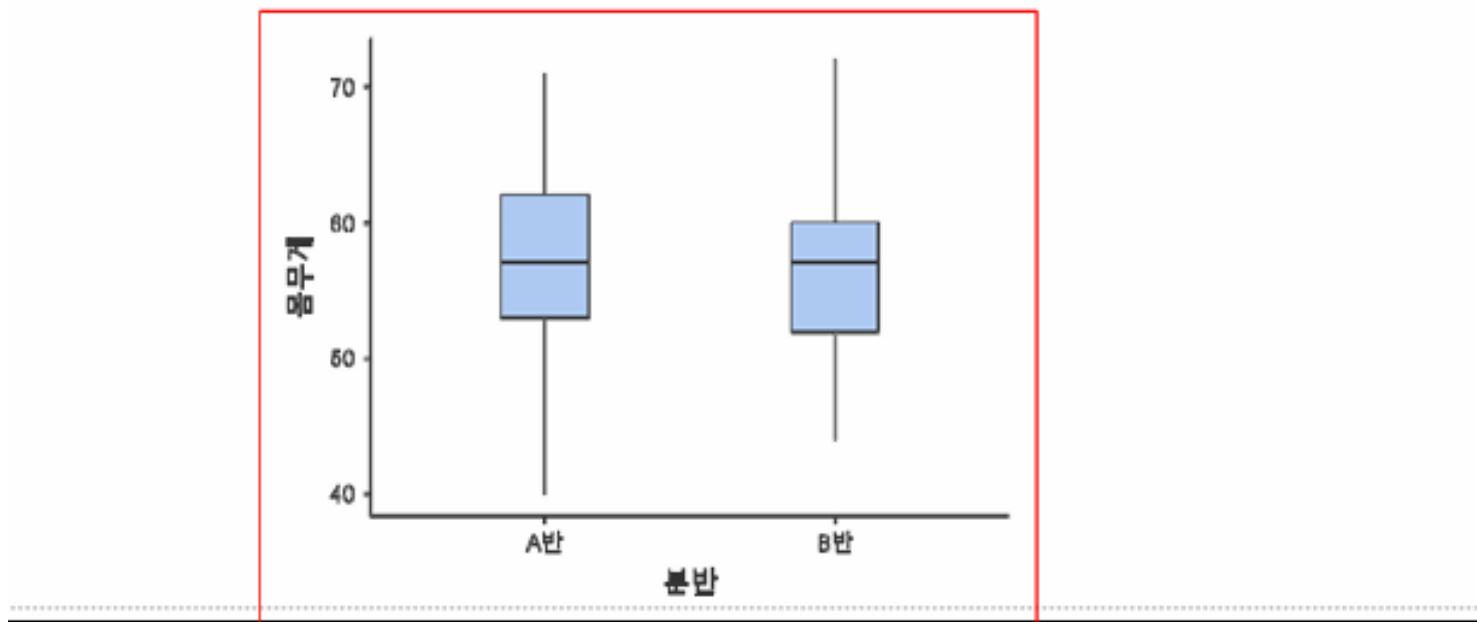
수치형 자료(다면량)

그룹별 수치자료 비교

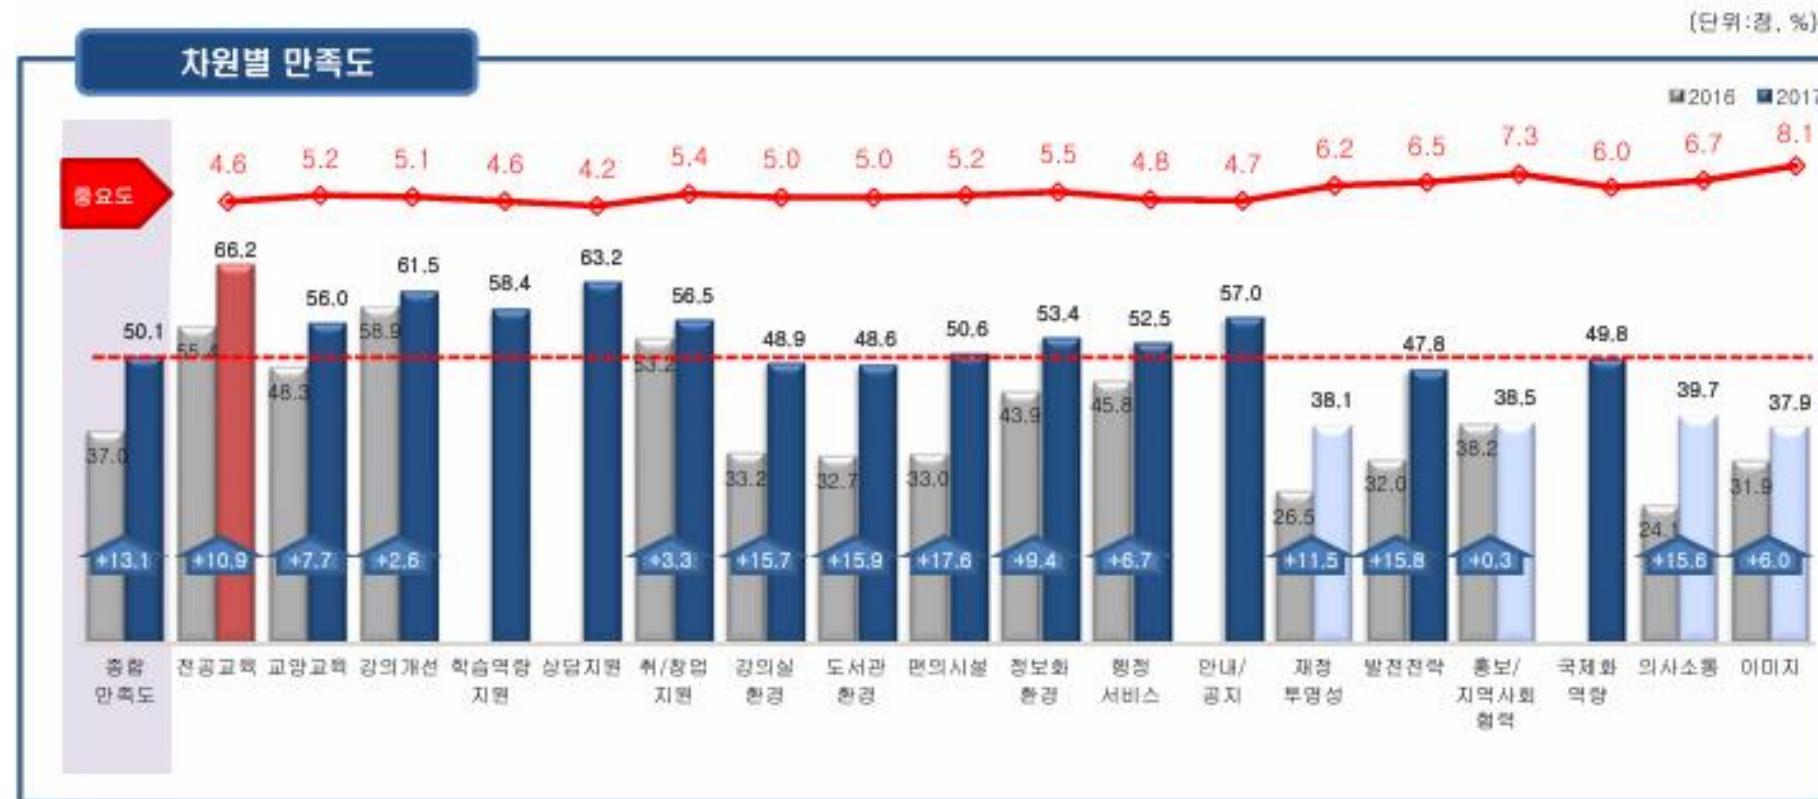
■ 그룹간 수치자료 비교

- 범주형 자료+ 수치형 자료
- 통계값: 표본크기, 평균, 표준편차

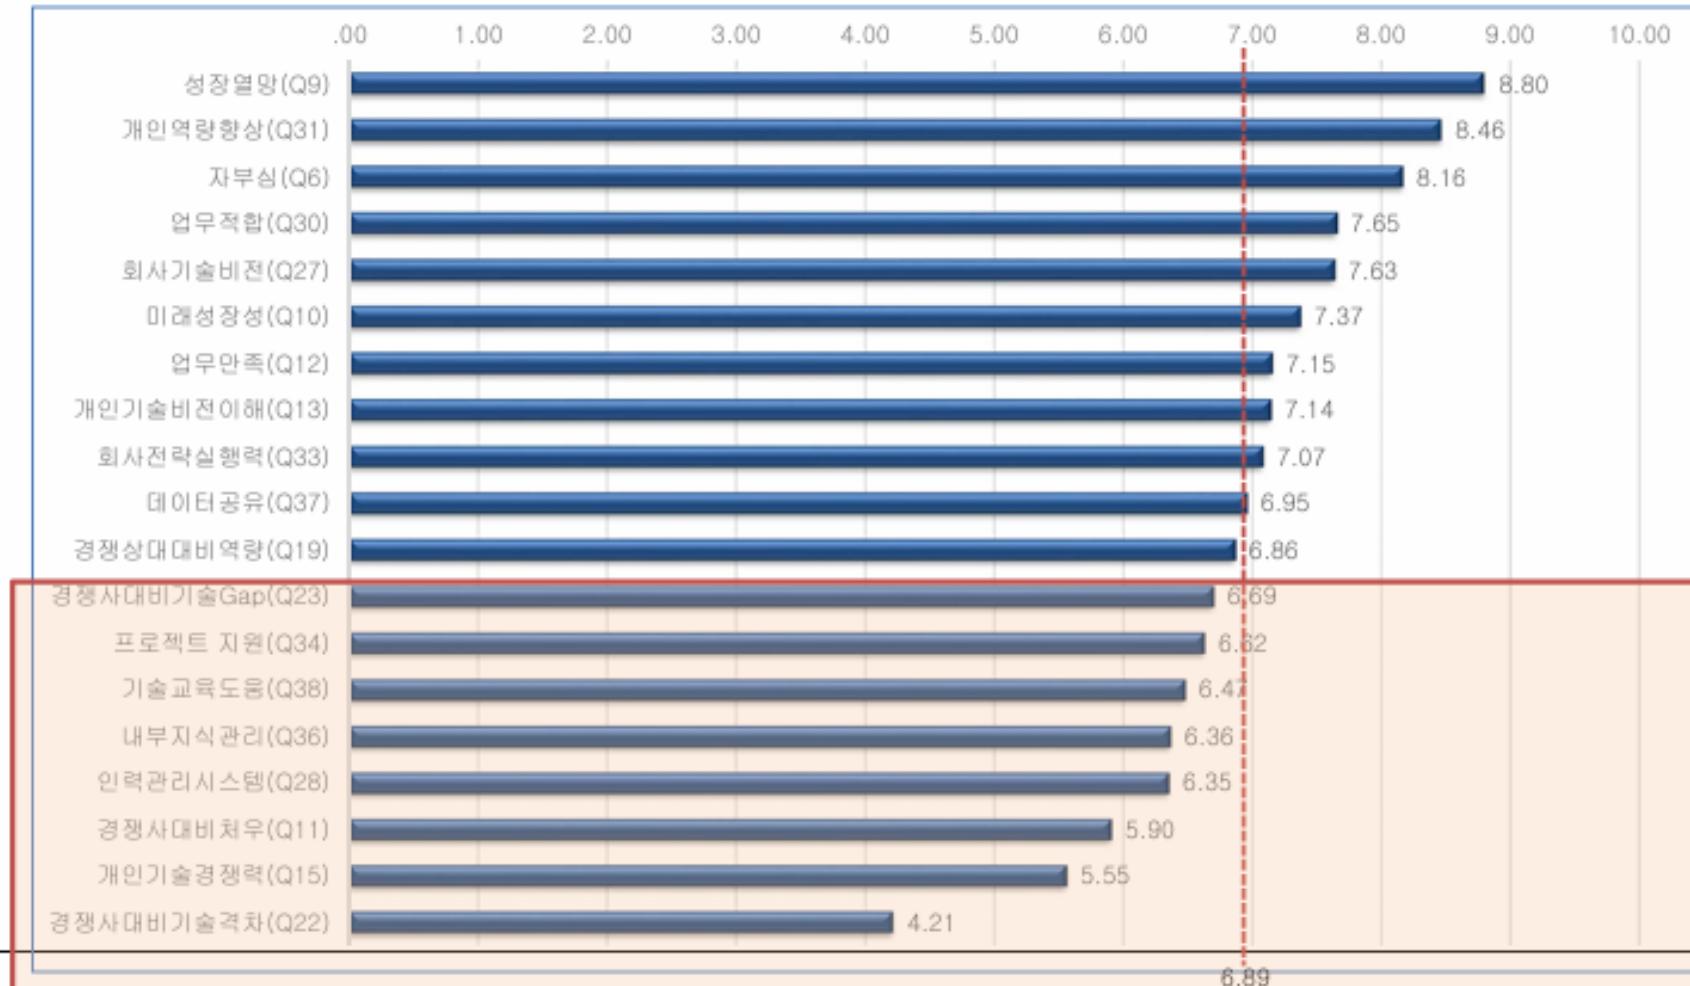
분반	N	Mean	Median	SD	Skewness	Kurtosis
A반	51	56.96	57	7.21	-0.17	-0.29
B반	49	56.59	57	6.41	0.22	-0.2



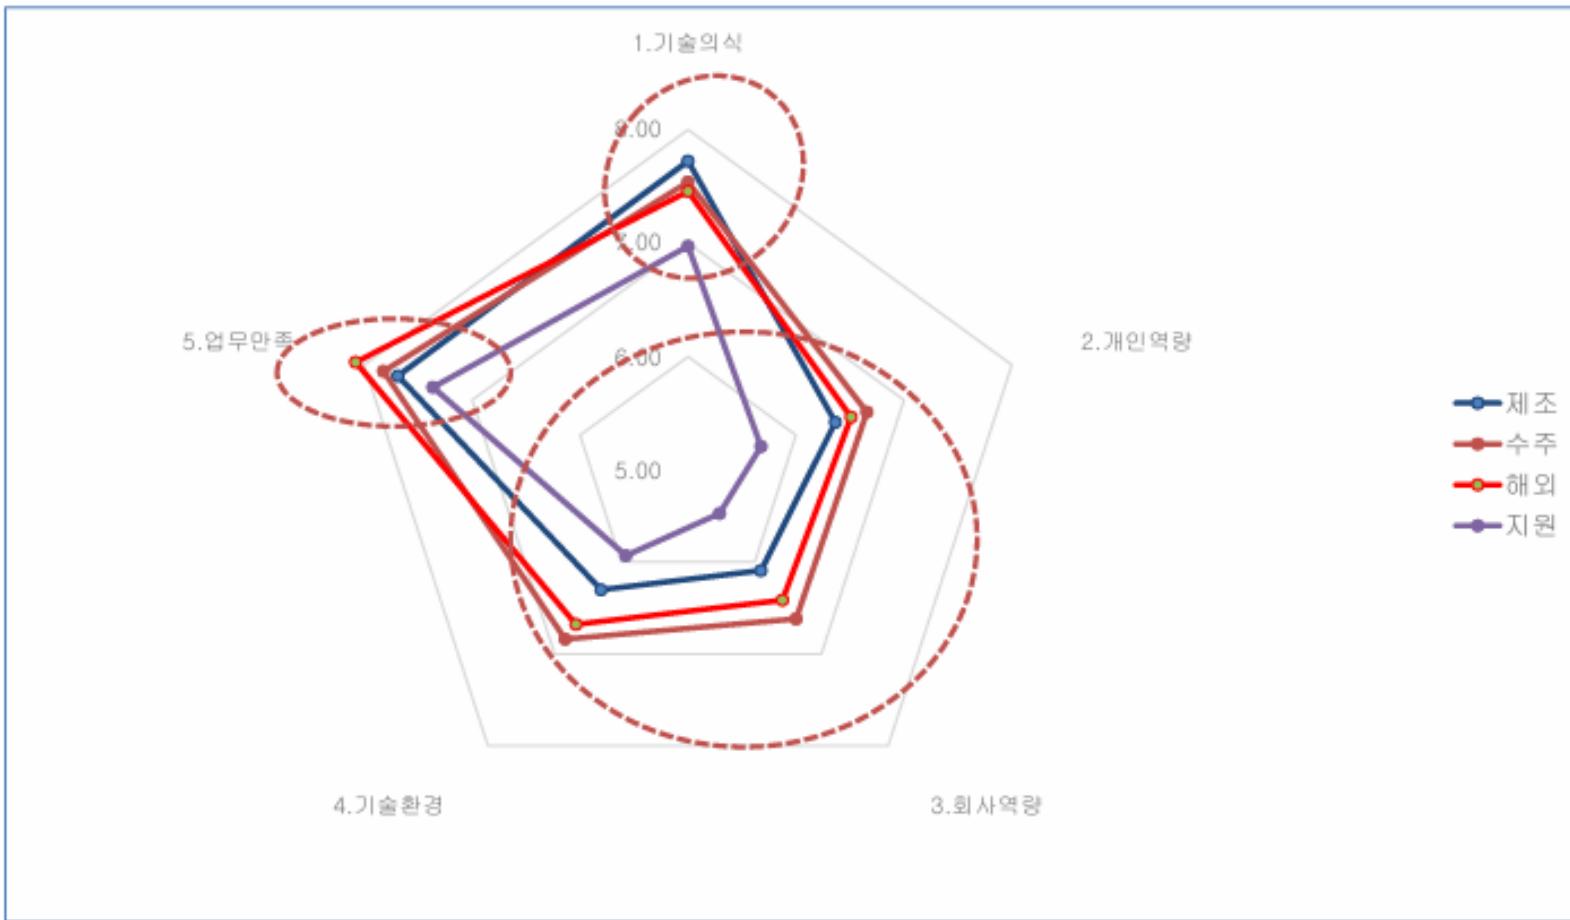
다면량 수치형 자료의 정리



다변량 수치형 자료의 정리



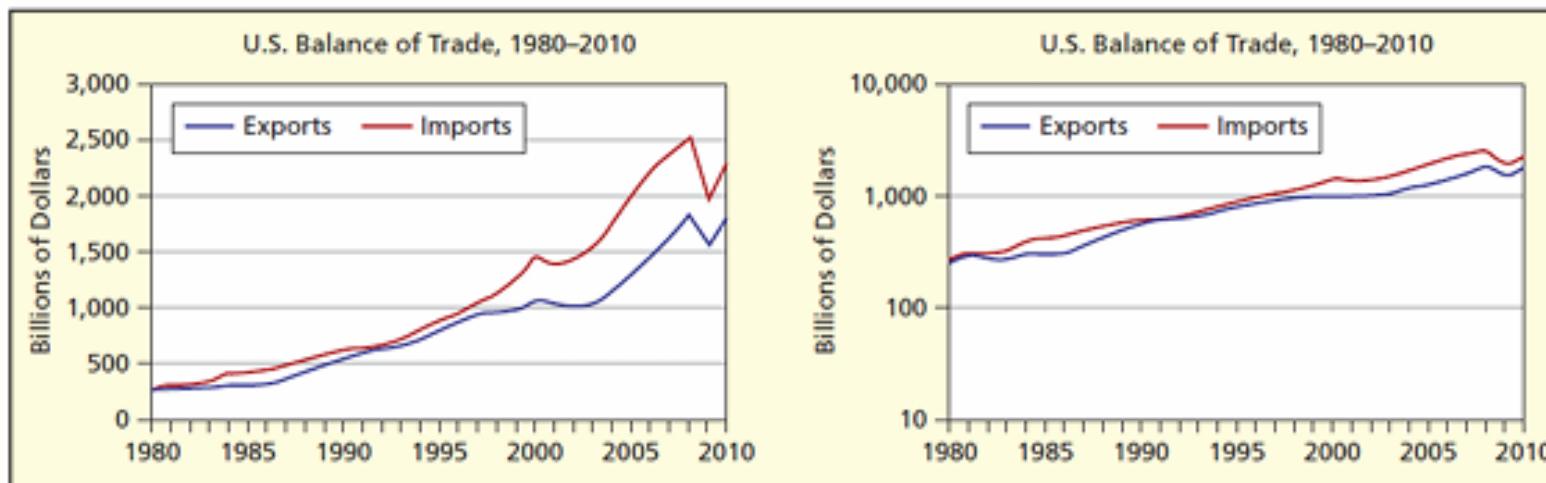
다변량 수치형 자료의 정리



시계열 자료

■ Time-series

- 시간의 변화에 따른 자료
- 예) 주식, GDP변화, 수출 등 경제관련 지표에서 많이 사용
- 자료의 값의 변화가 크기 때문에 log 값으로 변환해서 많이 사용



연습문제

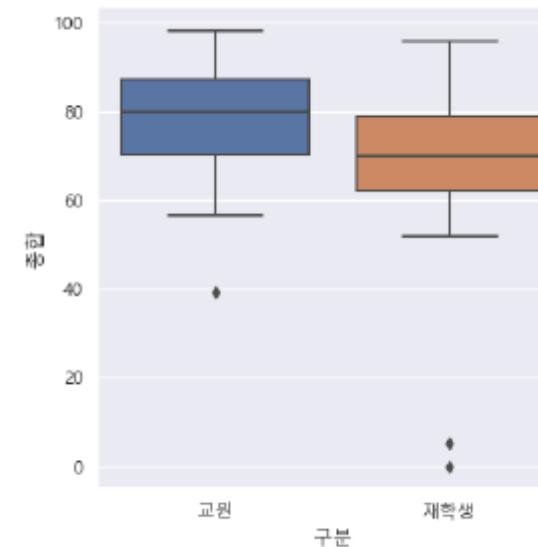
- 07. 온라인게임.csv를 이용하여 수치형 자료를 분석하세요.
 - Q1. 나이(age)의 기초통계분석(rstatix), 히스토그램(bins=10), 상자도표
 - Q2. age의 이상치 제거(± 3.0 이상만 제거)
 - Q3. age를 범주형으로 변환(10대, 20대, 30대 등으로 구분), 막대그래프 그리기
 - Q4. 성별에 따른 age의 점수를 구하고, box plot 그리기
 - Q5. Design과 Flow의 값 구하고, 산점도로 표시
 - Q6. 성별에 따른 Design과 Flow의 값 구하고, 산점도로 표시

데이터 분석 연습문제

■ 문제의 정의

- 대학에서는 재학생(1)과 교원(2)을 대상으로 교육과정에 대한 현황조사를 실시하였다.
- 종합점수가 재학생과 교원이 차이가 있는가?
- 09.edu.csv

구분	종합
0 재학생	0.0
1 재학생	5.0
2 재학생	70.8
3 재학생	71.6
4 재학생	71.7



	T	dof	alternative	p-val	CI95%	cohen-d	BF10	power
T-test	-3.462	95	two-sided	0.001	[-12.61, -3.42]	0.703	35.774	0.929

Q&A