

# 통계학의 이해

---

보건빅데이터통계분석


이새봄  
삼육대학교 SW융합교육원

# 통계학이란

# 여론조사

## ■ 20대 대통령 선거

- 2022.3.1~




# 여론조사


## 지상파방송3사 공동 2차 여론조사 조사개요

- 조사의뢰기관 KBS, MBC, SBS
- 조사기관 입소스, 코리아리서치, 한국리서치
- 조사지역 전국
- 조사기간 2022년 03월 01일 ~ 03월 02일(2일간)
- 조사대상 전국에 거주하는 만18세 이상 성인남녀
- 조사방법 국내 통신 3사가 제공하는 휴대전화가상(안심)번호(100%)를 이용한 전화면접조사
- 표본크기 2,003명
- 피조사자 성/연령/지역별로 피조사자를 할당
- 선정 방법
- 응답률 24.9% (총 8,037명과 동화하여 그 중 2,003명 응답 완료)
- 가중치 부여방식 지역별, 성별, 연령별 가중치 부여(셀가중)  
(2022년 1월말 행정안전부 주민등록인구통계 기준)
- 표본오차 95% 신뢰수준에서 ±2.2% point


# 여론조사



# 여론조사




# 여론조사



# 여론조사


## ■ 20대 대통령 선거(최종결과)



**표본오차가 무엇인가요?**

# 표본오차(오차범위)

- 신뢰구간: 모수가 있을 범위
  - 통계에서 많이 사용하는 신뢰수준: 95%



# 표본오차(오차범위)

■ 조사일시: 2022.2.13 ~ 19

조사기관	이재명	윤석열	응답수	표본오차
서던포스트	31.4%	40.2%	1,001	±3.1%
리얼미터	38.7%	42.9%	3,043	±1.8%
칸타코리아	32.2%	41.3%	1,012	±3.1%
한국갤럽	34%	41%	1,007	±3.1%
리서치뷰	39%	48%	1,000	±3.1%
KSOI	43.7%	42.2%	1,002	±3.1%
한국리서치	36.9%	42.4%	1,000	±3.1%

응답수	100	500	1,000	2,000	5,000	10,000	20,000
오차범위	9.8	4.4	3.1	2.2	1.4	1.0	0.7

# 오차범위와 통계

- K대학 통계학 수업 수강생 100명 몸무게를 조사
  - 평균, 표준편차

$$\mu = 56.78$$

$$\sigma = 6.80$$

- 몸무게가 55-60일 확률은?


$$P(55 \leq X \leq 60) = 0.31$$

- 몸무게 평균을 중심으로 95% 확률로 예측할 수 있는 몸무게의 범위는?

$$0.95 = P(45 \leq X \leq 70)$$




- 고등학교 수학은 몸무게의 범위를 이용해 확률을 구하였으나, 이제는 확률을 이용해 범위를 구하는 것이 핵심

X	빈도수	%	확률(p)
40-45	3	3	3
45-50	13	13	13
50-55	20	20	20
55-60	31	31	31
60-65	19	19	19
65-70	12	12	12
70-75	2	2	2
합계	100	1	1



# 정규분포


## ■ Normal Distribution



# 경험적 법칙


## ■ Empirical Rule (경험적 법칙)

- $k = 1$ , 68.26% 이상의 데이터가  $\mu \pm 1\sigma$  사이에 있음
- $k = 2$ , 95.44% 이상의 데이터가  $\mu \pm 2\sigma$  사이에 있음
- $k = 3$ , 99.73% 이상의 데이터가  $\mu \pm 3\sigma$  사이에 있음



# 확률과 오차 범위

- 통계적 방법론의 기초이론으로써 중요한 역할을 함
- 표본값을 이용해서 모수를 예측할 때 사용
- 모수가 있을 범위: 확률을 이용하여 모수를 추측



# 통계학이란

- 관심 대상인 모집단의 특성을 파악하기 위해
  - 문제: 모집단을 조사하기 어려움
- 모집단으로부터 관련된 일부 자료(표본)을 수집하고  
=> 표본추출 (Sampling)
- 수집된 표본의 자료를 요약하여 표본의 특성을 파악하고  
=> 기술통계학(descriptive statistics)
- 표본의 자료를 이용하여 모집단의 특성에 대한 확률을 이용해 추론하는 학문  
=> 추론(추측)통계학(inferential statistics)

# 통계학이란

- 통계에 근거하여 의사결정을 위한 분석 기술과 절차를 다루는 학문
- 데이터를 수집하고, 과학적으로 분석하여 의사결정에 활용하는 학문
- '집단 현상을 수량적으로 관찰하고 분석하는 방법' 을 연구하는 학문
- 특정 문제가 주어졌을 때, 합리적인 의사결정을 내리기 위해 통계기법을 도구로 사용하는 학문

# 기술통계학

## ■ 기술통계학(descriptive statistics)

- 조사 및 측정된 자료를 통해 그 자료가 가지고 있는 특징을 수치, 표, 그래프로 정리하는 과정

## ■ 범주형 자료

- S대학 경영학부의 남자와 여자의 성비

변수	항목	빈도	%
성별	남자	101	57.7
	여자	74	42.3
Total		175	100.0




## ■ 수치형 자료

- S대학 2학년 학생의 키: 평균 175 ±5cm

# 추론통계학

- 관심대상 전체로부터 일부의 샘플을 추출, 분석하여 그 결과로부터 전체 모집단에 대한 특성을 예측

- 사례1) 아이스크림의 용량은 320g을 판매해야 된다. A매장에서는 320g을 팔고 있는지 표본 100개를 가지고 확인해 보자.
- 사례2) 주택의 연면적에 따른 주택가격을 예측해보자.




# 모집단과 전수조사

- 모집단(population)
  - 관심 있는 연구대상 전체의 집합
  - 무한모집단: 모집단의 크기가 무한한 경우 (전세계 인구, 자판기 커피)
  - 유한모집단: 모집단의 크기가 유한한 경우 (삼육대학교 재학생)
- 전수조사
  - 관심 있는 모집단 전체를 조사하는 경우로서 주로 모집단의 규모가 작을 경우에 실시
- 전수조사의 어려움
  - 조사불가능: 모집단 전체를 대상으로 조사하기는 불가능
  - 시간과 비용: 모집단을 다 조사하는 데는 많은 시간과 비용 소요
- 해결책: 전수조사 → 표본조사

# 표본과 표본조사

## ▪ 표본 (Sample)

- 추출된 모집단 구성의 일부
- 모집단의 일부분으로부터 얻어진 관측 값의 집합



## ▪ 표본조사

- 모집단에서 추출된 일부부인 표본을 가지고 하는 조사
- 수집방법: 실험, 조사, 출판자료

# 모수와 통계량

- 모수(parameter):
  - 모집단에 대한 수치 특성값
  - 모집단의 특성을 나타내는 양적인 측도로서 주어진 모집단을 따르는 고유의 상수 (상수=모집단은 진실된 하나의 값임)
  - 모평균( $\mu$ ), 모표준편차( $\sigma$ )
  - 예) 우리나라 고등학교 사교육비 평균
  
- 통계량(statistic):
  - 표본에서 얻은 수치 특성값
  - 표본의 특성을 나타내는 양적인 측도로서 모집단의 분포를 따르는 확률변수
  - (확률변수=표본에 따라 값이 변함)
  - 표본평균( $X$ ), 표본표준편차( $s$ )
  - 예) 우리나라 고등학교 1학년 중에서 1000명만 뽑아 조사하여 얻은 평균 사교육비

# 표본오차와 통계적 추론

## ■ 표본오차(sampling error)

- 모집단에서 표본을 추출해서 조사하기 때문에 모수와 표본 통계량 사이에 생기는 오차
- 표본의 크기를 크게 함으로써 표본오차를 감소 → 통계학에서 표본의 크기를 크게 하라는 이유
- 표본오차는 아무리 표본을 크게 해도 전수조사를 하지 않는 이상 존재
- 표본오차의 허용범위를 **확률**로 구하는 것이 통계의 목적

## ■ 통계적 추론

- 우리가 실제로 알고 싶은 것은 표본의 값(통계량: statistic)이 아니고 모집단의 값(**모수: Parameter**)
- 통계학의 목적: **추론(Inference)** → 표본에서 구한 값을 이용해 우리가 구하고자 하는 모집단의 값도 이럴 것이다라고 추론

# 표본조사 방법

## ■ 확률추출(probability sampling)

- 모집단에 속하는 모든 추출단위에 대해 사전에 일정한 추출확률이 주어지는
- 표본추출법
- 표본추출률 존재
- 단순확률추출(simple random sampling)
- 계통추출법(systematic sampling)
- 층화확률추출(stratified random sampling)
- 집락추출법(cluster sampling)

## ■ 비확률추출

- 추출단위가 표본에 추출될 확률을 객관적으로 나타낼 수 없는 표본추출법
- 편의표출(convenience sampling)
- 할당추출(Quota sampling)
- 포커스 그룹(Focus Groups)

# 표본조사 방법

## ■ 기본용어

- 기본단위(elementary unity) : 조사의 대상이 되는 가장 최소의 요소
- 예) 여론조사 : 개인, 가계조사 : 가구, 농작물조사: 일정 면적의 경지

## ■ 추출틀(sampling frame) : 모집단에 속하는 모든 추출단위의 목록

- 예) 개인, 가구, 사업체 등의 명부, 문서철, 지도 등

## ■ 목표모집단(target population): 관심을 갖고 특성을 알아보고자 하는 집단에 속하는 모든 기본단위들의 집합

- 예) 삼육대학교 재학생 학부모

## ■ 조사모집단(target population): 표본 추출틀을 통해 추출될 수 있는 기본단위들의 집합(실제 조사 가능한 집단)


- 예) 전화조사 : 삼육대학교 재학생 학부모 중 전화번호가 있는 사람

# 통계 분석 방법

# 통계분석방법




- 평균차이검정
  - 집단간 평균차이를 검정하는 방법
  - 평균검정(T-test), 분산분석(ANOVA), ANCOVA, MANOVA
- 관계검정
  - 변수와 변수의 관계를 검정
  - 상관분석, 회귀분석, 교차분석, 정분상관분석, 판별분석, 로지스틱회귀분석
- 신뢰도와 타당도
  - 신뢰도분석, 요인분석
- 기타
  - 군집분석, 다차원척도법, 생존분석, 데이터마이닝 기법등

# 통계분석방법



# 차이검정


- |   |                                       |
|---|---------------------------------------|
| <input type="checkbox"/> 명목변수(Categorical: C) | <input type="radio"/> 연속변수(Metric: M) |
|---|---------------------------------------|



# 차이검정

- **분산분석(ANOVA)**
  - 집단이 3개 이상일 때
  - 일원배치 분산분석(One-Way ANOVA): 한 개의 집단구분변수
  - 이원배치 분산분석(Two-Way ANOVA) : 두 개의 집단 구분 변수를 동시에
  - 반복측정 분산분석(Repeated Measures ANOVA): 집단이 세 개이면서 반복 측정
- **평균분석(T-Test)과 분산분석(ANOVA)의 비교**
  - 왜? 평균분석을 3번 안 할까?
  - 예) 1,2,3 이라는 집단
  - 1:2, 2:3, 1:3 → 3번 평균비교 VS 분산분석(ANOVA) 1번
  - 여러 번 평균검정(T-test)를 해주게 되면 1종 오류를 범할 확률이 증가
$$1 - (1 - \alpha)^t = 1 - (1 - 0.5)^3 = 0.14$$
  - 3개 이상일 때는 모든 집단의 평균이 같은지를(1=2=3) 분산을 이용하여 분석
  - 분산분석을 실시한 후에 3 개의 집단 간에 평균이 틀리다고 밝혀지면 그때 비로서 각 집단간 3쌍의 평균을 비교
  - 이때도 Duncan, Tukey 등 1종 오류를 보정해 주는 방법을 이용해서 분석

# 차이검정




# 관계검정

## ■ 관계검정

- 변수와 변수의 관계를 검정
  - 상관분석(Correlation Test): 연속변수 + 연속변수
  - 회귀분석(Regression): 연속변수 + 연속변수
  - 교차분석(test): 질적변수 + 질적변수

## ■ 교차분석

- 2개의 질적변수



# 관계검정

## ▪ 상관분석(Correlation Test)




- 상관관계: 두 변수가 서로 동등한 입장에서 관계를 분석
- 예) 몸무게가 많이 나가면 허리둘레도 크고, 반대로 허리둘레가 크면 몸무게도 많이 나감
- 편상관분석(Partial Correlation) : 중간에 다른 변수의 영향력이 있을 때 이를 통제



## ▪ 회귀분석(Regression)

- 인과관계: 하나의 변수가 원인이 되어 다른 변수(들)에 영향을 미치는 관계

# 관계검정



# 차이검정

## ■ 평균차이검정

- 집단간 평균차이를 검정하는 방법
- 질적변수 1개 (집단구분) + 연속 변수 1개 (평균)
- 평균검정(T-test): 집단이 2개 미만 일 때
- 분산분석(ANOVA): 집단이 3개 이상일 때

## ■ 평균검정(t-검정)

- 단일 표본 t-검정(One Sample T test): 하나의 집단의 평균이 얼마인지를 검정
- 독립 두 표본 t-검정(Independent Samples T test): 흡연집단과 비흡연집단으로 나누어서 이 두 집단간의 제태기간의 차이가 있는지를 비교
- 대응표본 t-검정검정(Paired Samples T test): 하나의 집단이지만 이 집단을 처리전과 처리 후로 두 개로 나누어서 비교(다이어트효과)

# 통계적 추론의 종류

- 추정(Estimation)
  - 표본의 평균과 표준오차(SE)를 구해서 모수의 범위를 구하는 것
  - 신뢰구간: 일정한 확률범위 내에서 모수의 값이 포함될 가능성이 있는 범위
  - 90%, 95%, 99% 의 확률 값 중에서 95%
  - 종류: 점추정, 구간추정
  - 사례:  $\mu = 295.4 \pm 7.26, [288.14, 302.66]$
- 가설검정
  - 모수는 얼마이다라고 정하고 그것이 맞는지 틀리는지를 검증하는 방법
  - 유의수준 ( $\alpha$ ) : 모수와 통계량의 차이가 커서 확률적으로 가설을 기각할 수 있는 값
  - 1%, 5%, 10%의 값 중에서 5%
  - 종류: 귀무가설 (Null Hypothesis), 연구가설 (Alternative Hypothesis)
  - 사례:  $t_{cal} = -12.25 < t_{critical} = -1.984, p-value = 0.000 < \alpha = 0.05$

# 가설검정

## ■ 가설 검정(Hypothesis Test)

- 모집단 모수의 값을 설정하고(가설 설정), 표본 통계치를 통해 확률적으로 진위를 판정하는 과정

## ■ 가설유형

- 추론통계에서는 귀무가설과 대립가설을 세우고, 귀무가설이 기각됨을 통해 본래 알아보고자 한 대립가설이 통계적으로 유의한 것인지를 확인
- $H_0$ : 귀무가설(Null Hypothesis, 영가설)
  - 기존에 알려져 있는 사실(status quo), 통계적 검정 대상
  - 알아보고자 하는 내용과 반대되는 내용으로서 '두 변수 사이에 관계가 없다' 또는 '두집단은 차이가 없다'와 같이 부정적인 형태로 진술
- $H_1$ : 대립가설(연구가설)
  - 새로운 사실, 현재 믿음에 변화가 있는 사실, 뚜렷한 증거로 입증하려고 하는 주장
  - 알아보고자하는 내용으로서 '검정할 가설의 내용에는 차이가 있다' 또는 '효과가 있다' 와 같이 진술
- 사례) H자동차에서 만든 새로운 하이브리드 차량의 연비는  $16.5 \text{ km/l}$ 로 알려져 있다. 과연 진짜로  $16.5 \text{ km/l}$  인가를 검증

# 통계적 가설검정

- 통계적 가설검정: 귀무가설을 받아들일 것인지, 아니면 기각(reject)할 것인지를 검증
- 통계분석 귀무가설 설정(무죄주의의 원칙)

구분	방법	귀무가설
차이검정	$t - test$ , ANOVA	$H_0 : \mu_1 = \mu_2$
관계검정	regression	$H_0 : \beta = 0$

- 가설검정은  $H_0$ 가 진실인지를 검증함

# 가설 검정의 종류


귀무가설( $H_0$ )

$$H_0: \mu = 16.5$$

대립가설( $H_1$ )

- |                      |                        |
|----------------------|------------------------|
| $H_1: \mu \neq 16.5$ | 양측검정(two-sided test)   |
| $H_1: \mu > 16.5$    | 우측검정(right-sided test) |
| $H_1: \mu < 16.5$    | 좌측검정(left-sided test)  |

양측검정(two-sided test)



# 가설 검정의 종류


귀무가설( $H_0$ )

$$H_0: \mu = 15$$


대립가설( $H_1$ )

- |                    |                        |
|--------------------|------------------------|
| $H_1: \mu \neq 15$ | 양측검정(two-sided test)   |
| $H_1: \mu > 500$   | 우측검정(right-sided test) |
| $H_1: \mu < 5$     | 좌측검정(left-sided test)  |

$H_1$ : 우측검정(right-sided test)




$H_1$ : 좌측검정(left-sided test)



# 귀무가설의 기각 수준



- 가설을 검증할 때는 귀무가설이 채택될 가능성을 본다. 보통 신뢰도 95% 수준으로 본다.
- 따라서 귀무가설이 채택될 가능성이 평균을 중심으로 95% 구간에 있으면 귀무가설은 채택되고, 대립가설은 기각된다.  
즉, 본래 알아보고자 한 내용은 통계적으로 유의하지 않게 된다.
- 반대로 귀무가설이 채택될 가능성이 왼쪽 0.25%, 오른쪽 0.25% 구간에 속하게 되면 귀무가설은 기각되고,
- 대립가설이 채택된다. 즉, 본래 알아보고자 한 내용이 통계적으로 유의하다는 의미이다.



# 귀무가설의 기각 수준

## ■ p-value

- 이 때 사용된 기준을 유의수준이라고 하고 이 경우에는 5% 즉, 0.05가 귀무가설이 기각되고 대립가설이 채택될 수 있는 기준이 된다.
- 분석결과 가설이 속할 확률인 유의확률 p-value가 0.05보다 크면 귀무가설을 채택하고, 0.05보다 작으면 대립가설을 채택한다.
- 보다 유의한 수준을 보기 위해서는 p-value가 0.01보다 작은지를 본다



# Q&A